




Medición e identificación de variables para la estadística descriptiva y exploratoria de manantiales

Vargas Gómez, Santiago¹; Vargas Gómez, Cristian²

Departamento de Estadística, Universidad Nacional de Colombia

1 de agosto de 2026

Resumen: Este artículo se enfocará en el análisis de un conjunto de datos numéricos y no numéricos que brindan información sobre la localización, características del punto de emergencia (o sitios de prevención) y composición química de más de 300 de los manantiales existentes en la región de Colombia, contribuyendo así a localizar y caracterizar los yacimientos geotérmicos existentes a lo largo del extenso territorio del país. Los datos fueron obtenidos del Portal de Datos Abiertos del servicio geológico colombiano. Palabras clave: Manantiales, Fumarolas,

Dataset, Estadística, Elementos.

1. Introducción

El estudio de las fuentes termales y manantiales en Colombia constituye una ventana directa hacia la complejidad de los sistemas hidrogeológicos y geotérmicos del país. Debido a su ubicación en una zona de convergencia tectónica y actividad volcánica significativa, el subsuelo colombiano alberga fluidos que han interactuado con diversas litologías en condiciones de alta presión y temperatura. El presente trabajo analiza el inventario geoquímico de puntos de agua subterránea, una base de datos fundamental para la gestión e identificación de recursos hídricos, junto con la exploración de energías renovables.

A través de la caracterización de variables que van desde los parámetros fisicoquímicos básicos hasta la presencia de elementos traza como el Litio, el Cesio y el Antimonio, así como el análisis de isótopos estables como el Deuterio, es posible rastrear el ciclo del agua desde su recarga en las altas cumbres hasta su descarga en los manantiales. Estos componentes no solo funcionan como indicadores de la calidad del agua y su aptitud para el consumo humano, sino que actúan como “trazadores químicos” que revelan la profundidad de los reservorios, el tiempo de residencia en la roca y la influencia de fluidos magmáticos o fallas geológicas activas.

A través de este análisis, se busca describir una parte de la composición química de los manantiales, comprendiendo la metodología detrás de las mediciones realizadas y la relevancia de cada una de las variables en la interpretación de los procesos geológicos que moldean nuestro territorio. Comprender la importancia y la influencia de las variables en el conjunto de datos es útil para saber la influencia que cada una de ellas tiene en la estimación de situaciones que dependen del tiempo, ayudando a comprender de qué manera se comportará el manantial en los próximos 5 o incluso 10 años y por qué ciertas de sus características se complementan para dar paso a fenómenos naturales.

2. Objetivos del Análisis Exploratorio de Datos

2.1. Describir la distribución de las variables fisicoquímicas principales

Se busca caracterizar la distribución de las variables fisicoquímicas más representativas del estado del manantial: pH, temperatura, conductividad, y las concentraciones de sodio y calcio. Estas variables fueron seleccionadas debido

a su relevancia en la evaluación de la calidad del agua y a la amplitud de sus rangos de valores.

Para este propósito, se emplean histogramas, diagramas de caja y funciones de densidad. En particular, la conductividad presenta un rango amplio (de 0 a 278,000 $\mu\text{S}/\text{cm}$), lo que evidencia variabilidad significativa incluso antes del proceso de limpieza de datos.

2.2. Asociar la incidencia de propiedades geoquímicas en el olor del agua

El objetivo es determinar cuál es el tipo de agua predominante en el conjunto de datos. Para ello, se analizan las variables categóricas CLASIFICACIÓN y OLOR, ya que son las únicas que presentan un significado geoquímico relevante, frente a la generación de subproductos como el CO_2 y el H_2S .

Se utilizan gráficos de barras y diagramas de pastel (*pie chart*), que permiten visualizar la frecuencia relativa de cada categoría y facilitar la identificación de las clases dominantes.

2.3. Comparar el olor del agua según su tipo

Se pretende analizar la relación entre el tipo de agua y su olor, utilizando conjuntamente las variables categóricas CLASIFICACIÓN y OLOR.

Para este análisis se emplean gráficos de barras comparativas, los cuales permiten observar cómo se distribuyen los diferentes olores dentro de cada tipo de agua. Esta relación es particularmente relevante desde el punto de vista geoquímico, ya que ciertos tipos de agua, como las sulfatadas, suelen asociarse con ambientes volcánicos que generan sulfuro de hidrógeno (H_2S), responsable del característico olor a huevo podrido.

2.4. Identificar el estado del dataset antes de la limpieza

Se busca evaluar la calidad y completitud del conjunto de datos previo a su procesamiento. Este análisis es fundamental para justificar la necesidad de aplicar técnicas de limpieza.

Para ello, se utilizan gráficos de barras que muestran la cantidad de mediciones por año, así como mapas de datos faltantes que permiten identificar patrones de ausencia de información. Estos elementos proporcionan una visión clara del estado inicial del dataset, respaldan las decisiones metodológicas tomadas en etapas posteriores del análisis y justifican los criterios de exclusión e imputación aplicados sobre valores cero no representativos.

2.5. Determinar si las propiedades fisicoquímicas permiten distinguir grupos naturales de manantiales

Se busca establecer si existen subconjuntos de manantiales con características fisicoquímicas similares, lo que permitiría identificar tipos de sistemas hídricos diferenciados dentro del territorio colombiano. Para ello se definen criterios de agrupamiento basados en distancias entre las variables numéricas seleccionadas, y los grupos resultantes se caracterizan visualmente mediante diagramas ilustrativos y Rostros de Chernoff, una técnica que codifica múltiples variables simultáneamente en rasgos faciales, facilitando la comparación intuitiva entre grupos.

2.6. Examinar la asociación entre las variables fisicoquímicas

Se busca determinar qué tan relacionadas están entre sí las variables fisicoquímicas del manantial y si esas relaciones son consistentes. Dado que estas variables presentan distribuciones asimétricas y valores atípicos, se emplean las correlaciones de Spearman y Kendall como medidas no paramétricas de asociación monótona. La comparación entre ambas matrices permite evaluar la robustez de las relaciones identificadas frente a diferentes supuestos sobre la estructura de los datos.

2.7. Establecer qué tan similares son los manantiales en sus características cualitativas

Más allá de las variables numéricas, se busca cuantificar la semejanza entre manantiales a partir de sus atributos cualitativos, como el tipo de agua y el olor. Dado que las medidas de distancia numéricas no son aplicables a

variables categóricas, se seleccionan y presentan medidas de similaridad apropiadas para este tipo de datos, con el fin de identificar patrones de co-ocurrencia entre características geoquímicas y sensoriales.

2.8. Estimar la forma real de la distribución de las variables fisicoquímicas

Los histogramas dependen del número de intervalos elegido y pueden ocultar detalles de la distribución subyacente. Por ello, se busca obtener una estimación más continua y flexible de la densidad de cada variable mediante métodos kernel. Se analiza el efecto del ancho de banda sobre el suavizamiento de la estimación y se comparan distintas funciones kernel para un mismo ancho de banda, evaluando en cada caso la calidad del ajuste frente al histograma correspondiente.

3. Identificación y clasificación de datos

Se hizo una descripción de la función de cada una de las variables y las unidades en las que se mide cada una de ellas.

1. **ID_MANANTIAL:** Este dato numérico es un código único para la identificación del afloramiento de agua.
2. **LATITUD/LONGITUD:** Estos datos numéricos se refieren a las coordenadas geográficas tomadas en grados decimales con el fin de acoplarse al estándar del GPS.
3. **FECHA:** Dato numérico que indica el día y hora en que se realizó la medición o toma de muestra.
4. **CAUDAL:** Este dato numérico decimal expresa la cantidad de volumen de agua que pasa por el área determinada de cada manantial, es posible que el calculo se haya realizado a partir de la siguiente fórmula

$$Q = \frac{V}{t} \quad (1)$$

en donde **V** expresa el volumen y **t** el tiempo.

5. **TEMPERATURA:** Dato numérico decimal que expresa la temperatura del agua en su punto de salida (útil para clasificar si es agua fría o termal).
6. **OLOR:** Dato alfabético que describe sensorialmente el olor del agua.
7. **CARBONATO_/BICARBONAT:** Dato numérico decimal que tiene la cantidad en miliequivalentes por litro (mEq/l) de carbonatos y bicarbonatos; útil para la determinación del pH.
8. **SULFURO_HI:** Dato numérico decimal que indica la cantidad de ácido sulfúrico (H_2SO_4), este ácido es determinante para la reducción del pH del agua.
9. **PH_LABORATORIO:** Medición final del pH de las muestras de agua tomadas.
10. **CONDUCTIVIDAD:** Dato numérico que indica la capacidad del agua para conducir electricidad; indica la cantidad total de sales disueltas y está dado en microsiemens por centímetro:

$$\frac{\mu S}{cm} \quad (2)$$

11. **ALCALINIDAD:** Dato numérico decimal que expresa la capacidad del agua para neutralizar ácidos; se expresa principalmente en miligramos por litro de carbonato de calcio:

$$\frac{mg}{L} \quad CaCO_3 \quad (3)$$

12. **SOLIDOS:** Dato numérico decimal que representa la cantidad de material orgánico e inorgánico disuelto o suspendido presente en un volumen de agua; se expresa en miligramos por litro o partes por millón (*ppm*):

$$\frac{mg}{L} \quad (4)$$

13. **CLORUROS:** Dato numérico decimal que representa la masa de iones de cloro que provienen de disolución de minerales en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (5)$$

14. **SULFATOS:** Dato numérico decimal que representa la masa de sales ácido sulfúrico que provienen de erosión de minerales en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (6)$$

15. **NITRATOS:** Dato numérico decimal que representa la masa de nitratos que provienen de contaminación por uso de fertilizantes agrícolas en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (7)$$

16. **CALCIO:** Dato numérico decimal que representa la dureza del agua y la disolución de rocas calizas o dolomías.

17. **MAGNESIO:** Dato numérico decimal que representa la masa de magnesio que proviene de la erosión en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (8)$$

18. **ESTRONCIO:** Dato numérico decimal que representa la masa de estroncio que proviene de la erosión natural en un volumen de agua; se expresa en microgramos por litro:

$$\frac{\mu g}{L} \quad (9)$$

19. **SODIO:** Dato numérico decimal que representa la masa de sales de sodio que proviene de la erosión en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (10)$$

20. **POTASIO:** Dato numérico decimal que representa la masa de potasio que proviene de la interacción del agua con las rocas en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (11)$$

21. **HIERRO:** Dato numérico decimal que representa la masa de hierro que proviene de la disolución natural de minerales en el subsuelo en un volumen de agua; se expresa en microgramos por litro:

$$\frac{\mu g}{L} \quad (12)$$

22. **MANGANESO:** Dato numérico decimal que representa la cantidad de manganeso presente en cada manantial bajo el estándar de miligramos por litro; útil para indicar si el agua ha estado en un ambiente anóxico (sin oxígeno):

$$\frac{mg}{L} \quad (13)$$

23. **ALUMINIO:** Dato numérico decimal que representa la masa de aluminio que proviene de disolución natural en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (14)$$

24. **SILICIO:** Dato numérico decimal que representa la masa de silicio en un volumen de agua; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (15)$$

25. **SILICE:** Dato numérico decimal que representa la cantidad de sílice que hay en cada manantial, es importante en geotermia para calcular la temperatura de lo que podemos denominar un “estanque” profundo; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (16)$$

26. **BORO:** Dato numérico decimal que representa la masa de boro en un volumen de agua, su análisis se realiza para conocer su conveniencia para consumo humano; se expresa en microgramos por litro:

$$\frac{\mu g}{L} \quad (17)$$

27. **LITIO:** Dato numérico decimal que representa la cantidad de litio que hay en cada manantial, indica que el agua ha tenido un largo tiempo de residencia en el subsuelo o que ha circulado a grandes profundidades, lo que da lugar a posibles interacciones con rocas ígneas lo cual es clave para identificar sistemas geotérmicos o aportes de aguas profundas. Se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (18)$$

28. **FLUOR:** Dato numérico decimal que representa la masa de fluoruro de calcio en un volumen de agua, proviene de la meteorización de rocas ricas en minerales; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (19)$$

29. **MERCURIO:** Dato numérico decimal que representa la masa de mercurio en un volumen de agua, proviene principalmente por la contaminación debido a la minería ilegal; se expresa en microgramos por litro:

$$\frac{\mu g}{L} \quad (20)$$

30. **ZINC:** Dato numérico decimal que representa la cantidad de zinc en un volumen de agua, sirve como un indicador de la interacción que existe entre el agua y la roca con depósitos de sulfuros; es una herramienta clave para la prospección geoquímica. Las anomalías en su concentración pueden revelar la presencia de mineralizaciones metálicas ocultas en el subsuelo o alertar sobre procesos de contaminación por actividades industriales y mineras.

$$\frac{\mu g}{L} \quad (21)$$

31. **YODURO:** Dato numérico decimal que representa la masa de iones de yodo en un volumen de agua, proviene de la erosión natural y su concentración es más escasa en zonas montañosas; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (22)$$

32. **BROMURO:** Dato numérico decimal que representa la masa de bromuro en un volumen de agua, se presenta mayormente en zonas con depósitos salinos o influencia marina; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (23)$$

33. **NIQUEL:** Dato numérico decimal que representa la masa de níquel presente en un volumen de agua, su presencia es útil para la exploración geológica puesto que suele estar asociado a la degradación parcial o total de las rocas y los minerales, se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (24)$$

34. **ARSENICO:** Dato numérico decimal que identifica la cantidad de arsenico presente en el agua de los manantiales. Este elemento se encuentra en trazas muy pequeñas pero significativas debido a que permite identificar si el agua de un manantial es apta para el consumo humano. Se suele medir en microgramos por litro:

$$\frac{\mu g}{L} \quad (25)$$

35. **ANTIMONIO:** Dato numérico decimal que representa la masa de antimonio en un volumen de agua, proviene tanto de forma natural por la meteorización de minerales de sulfuro como contaminación por minería; se expresa en microgramos por litro:

$$\frac{\mu g}{L} \quad (26)$$

36. **CESIO:** Dato numérico decimal que representa la masa de cesio presente en un volumen de agua, el cesio es fundamental como un indicador de sistemas geotérmicos de alta temperatura, debido a que se libera de las rocas cuando el agua subterránea alcanza temperaturas muy altas, se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (27)$$

37. **RUBIDIO:** Dato numérico decimal que representa la masa de rubidio presente en un volumen de agua, debido a que tiene una gran similitud química con el potasio, la relación entre el rubidio y otros elementos permite determinar la estabilidad de los fluidos térmicos y confirmar si el agua ha circulado por niveles profundos de la corteza terrestre, se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (28)$$

38. **DEUTERIO:** Dato numérico decimal que representa la masa de deuterio presente en un volumen de agua, sirve para determinar el origen y la altitud de recarga del agua, se mide en ppm (partes por millón).

39. **OXIGENO18:** Dato numérico decimal que representa la masa del isótopo de oxígeno en un volumen de agua, se utiliza para identificar fuentes de agua, identificar la mezcla, altitud y temperatura de precipitación; se expresa en partes por millón (*ppm*).

40. **GAS CARBON:** Dato numérico decimal que representa la masa de CO₂ presente en un volumen de agua, su presencia indica el grado de interacción con fuentes profundas y se mide en miligramos por litro.

$$\frac{mg}{L} \quad (29)$$

41. **SULFURO₁**: Dato numérico decimal que representa la masa de ácido sulfhídrico presente en un volumen de agua, su presencia indica condiciones de reducción total (ausencia de oxígeno) y suele estar vinculado a dos orígenes principales y se mide en miligramos por litro:

$$\frac{mg}{L} \quad (30)$$

42. **METANO**: Dato numérico decimal que representa la masa de metano presente en un volumen de agua, su monitoreo es clave para la seguridad, ya que el metano es un gas inflamable, y en la exploración de recursos puede dar pistas sobre la proximidad de yacimientos de gas natural. Se mide en miligramos por litro:

$$\frac{mg}{L} \quad (31)$$

43. **ARGÓN**: Dato numérico decimal que representa la masa de argón presente en un volumen de agua, el argón indica la influencia de la atmósfera en el sistema subterráneo y se mide en miligramos por litro:

$$\frac{mg}{L} \quad (32)$$

44. **NITRÓGENO**: Dato numérico decimal que representa la masa de nitrógeno presente en un volumen de agua, el nitrógeno gaseoso sirve para verificar si hubo contacto excesivo con el aire durante la toma de la muestra o si existen procesos de desnitrificación biológica en el subsuelo. Se mide en miligramos por litro:

$$\frac{mg}{L} \quad (33)$$

45. **HELIO**: Dato numérico decimal que representa la masa de helio presente en un volumen de agua, su presencia es una señal clara de que existen fracturas profundas que conectan el manantial con rocas muy antiguas o con actividad magmática, funcionando como un “mensajero” de lo que ocurre a kilómetros de profundidad. Se mide en centímetros cúbicos por kilogramo:

$$\frac{cm^3}{kg} \quad (34)$$

46. **HIDRÓGENO**: Dato numérico decimal que representa la masa del hidrógeno en un volumen de agua, proviene del subsuelo mediante reacciones geoquímicas y se encuentra disuelto como gas natural; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (35)$$

47. **RADÓN**: Dato numérico decimal que representa la masa de radón en un volumen de agua, proviene de la erosión del uranio, torio y radio en suelos subterráneos, se encuentra en niveles más altos en áreas con granito o uranio en el subsuelo, disolviéndose fácilmente en aguas subterráneas; se expresa en becquerelios por litro:

$$\frac{Bq}{L} \quad (36)$$

48. **PH_{INSITU}**: Medición inicial del pH en el sitio de la toma de muestras.

49. **AMONIO**: Dato numérico decimal que representa la masa de amonio en un volumen de agua, proviene de descomposición natural de los suelos con materia orgánica y hierro, su disposición en manantiales puede indicar contaminación por residuos fecales; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (37)$$

50. **OXIGENO:** Dato numérico decimal que representa la masa de oxígeno disuelto en un volumen de agua, proviene del agua del subsuelo y suele ser escaso una vez sale del manantial; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (38)$$

51. **OBSERVACIO:** Dato alfabético que señala comentarios o apreciaciones adicionales sobre la ubicación, estado, y demás temas de interés.
52. **DEPOSITO_:** Dato alfabético que indica sobre que tipo de depósitos se encuentra ubicado el manantial.
53. **CLASIFICACIÓN:** Dato alfabético que muestra la clasificación del manantial dependiendo de sus cationes y aniones predominantes.
54. **MONOXIDO_C:** Dato numérico decimal que representa la cantidad de monóxido de carbono disuelto en un volumen de agua, proviene de la degradación de carbono orgánico y se encuentra con mayor frecuencia en zonas volcánicas; se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (39)$$

55. **FOSFATOS:** Dato numérico decimal que representa la cantidad de ortofosfatos, polifosfatos y fosfatos orgánicos disueltos en un volumen de agua, provienen de la erosión de suelos y rocas, y de la descomposición de material orgánico; se mide en miligramos por litro:

$$\frac{mg}{L} \quad (40)$$

4. Análisis de variables, categorización y limpieza de datos

En esta sección se expondrán los problemas encontrados en el dataset relacionados con datos faltantes o incompletos; se planteará una solución de estandarización de errores y valores faltantes para que no generen ruido en el momento de utilizar los datos para estimaciones y posibles predicciones. Es importante generar una categorización de las variables para que sean más fáciles de analizar y utilizar. El conjunto de datos engloba variables que son elementos químicos, por lo que resulta pertinente clasificarlos según la incidencia que tienen en los procesos fisicoquímicos que afectan las características de cada uno de los manantiales identificados.

5. Variables removidas

5.1. A. Variables con Varianza Cero (10 variables eliminadas/ignoradas)

1. GAS_CARBON

- **Razón:** Todos los valores = 0
- **Significado:** No se midió gas carbónico en ninguna muestra.
- **Impacto:** Sin variabilidad y por ende, sin información predictiva.

2. SULFURO_1

- **Razón:** Todos los valores = 0
- **Nota adicional:** Es un duplicado de SULFURO_HI (que sí tiene variabilidad). Esta variable probablemente fue un error de registro duplicado.

3. METANO

- **Razón:** Todos los valores = 0
- **Contexto:** El metano es un gas que puede indicar actividad orgánica o volcánica.

4. ARGON

- **Razón:** Todos los valores = 0
- **Significado:** Gas noble que no se midió o no se detectó.

5. NITROGENO

- **Razón:** Todos los valores = 0
- **Contexto:** Gas disuelto que podría indicar contacto con atmósfera.

6. HELIO

- **Razón:** Todos los valores = 0
- **Contexto:** Gas noble usado en estudios de origen de agua (profundo vs superficial).

7. HIDROGENO

- **Razón:** Todos los valores = 0
- **Contexto:** Gas que puede indicar procesos redox o actividad geotérmica.

8. RADON

- **Razón:** Todos los valores = 0
- **Contexto:** Gas radiactivo importante para salud pública, pero no fue medido.

9. OXIGENO

- **Razón:** Todos los valores = 0
- **Nota:** Diferente de OXIGENO18 (isótopo) que SÍ se conservó.

10. MONOXIDO_C

- **Razón:** Todos los valores = 0
- **Significado:** Monóxido de carbono, no detectado.

5.2. B. Variables Duplicadas (5 variables eliminadas, se conservó 1 de cada par)

Estas variables representan las mismas mediciones pero en diferentes formatos, unidades o momentos. Se conservó la versión con más datos válidos o más confiables.

11. BICARBON_1 (Eliminada, se conservó BICARBONAT)

- **Análisis:** Ambas tienen 320 valores válidos (sin diferencia).
- **Decisión:** Se conservó BICARBONAT porque es el nombre más estándar.
- **Impacto:** Ninguno, son idénticas.

12. CARBONATOS (Eliminada, se conservó CARBONATO_)

- **Análisis:** Ambas tienen 320 valores válidos.
- **Decisión:** Se conservó CARBONATO.
- **Impacto:** Ninguno, datos idénticos.

13. PH_IN_SITU (Eliminada, se conservó PH_LABORATORIO)

- **Razón:** Representa pH medido en campo vs laboratorio.
- **Análisis:** Es mejor conservar la medida de pH en laboratorio, pues suele ser más precisa gracias al uso de equipos calibrados.
- **Decisión:** Conservar PH_LABORATORIO.

14. CONDUCTIVIDAD_ELÉCTRICA (Eliminada, se conservó CONDUCTIVIDAD)

- **Razón:** Mismo parámetro, probablemente diferente método o instrumento.
- **Decisión:** Se conservó CONDUCTIVIDAD.

15. SILICE (Eliminada, se conservó SILICIO)

- **Contexto químico:** Sílice es el compuesto (SiO_2) y Silicio el elemento (Si). En análisis de agua, miden lo mismo con un factor de conversión.
- **Decisión:** Se conservó SILICIO (representa el elemento, más fundamental).

6. Metodología

El análisis exploratorio se realizó en el entorno de programación estadística R, utilizando principalmente las librerías ggplot2 para la visualización, dplyr y stringr para la manipulación de datos, y moments para el cálculo de asimetría y curtosis. El flujo de trabajo se dividió en dos archivos: funciones.r, que define las funciones personalizadas reutilizables (moda, meda y normalizar), y Script.r, que ejecuta el análisis sobre el conjunto de datos.

6.1. Selección de variables

De las 64 columnas originales del dataset, se descartaron las variables con varianza cero (todos los valores iguales a cero, sin información) y las variables duplicadas, según lo establecido en la Sección 4. Para el análisis exploratorio se conservaron:

- **5 variables numéricas:** PH_LABORATORIO, TEMPERATUR, CONDUCTIVIDAD, CALCIO, SODIO. Estas variables representan los parámetros fisicoquímicos más relevantes para caracterizar un manantial y son las que tienen mayor cobertura de datos en el dataset.
- **3 variables no numéricas:** CLASIFICACIÓN, OLOR, y FECHA. De esta última se extrajo el año (ANIO) como variable temporal categórica.

6.2. Medidas estadísticas utilizadas

Para cada variable numérica se calcularon las siguientes medidas, seleccionadas en función de las características observadas en los datos crudos:

- **Media y mediana:** medidas de tendencia central básicas. Se calcularon ambas porque su comparación directa permite detectar asimetría sin necesidad de graficar.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ es impar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{si } n \text{ es par} \end{cases}$$

- **Media recortada al 5 %:** se aplicó en todas las variables numéricas porque el dataset contiene valores atípicos extremos (por ejemplo, conductividad de hasta 278,000 $\mu\text{S}/\text{cm}$ o sodio de hasta 16,926 mg/L). La media recortada elimina el 5 % de los valores más altos y más bajos antes de promediar, produciendo un estimador más representativo del comportamiento típico. En R se obtiene con `mean(x, trim = 0.05)`.
- **Moda:** valor más frecuente. R no incluye esta función de forma nativa, por lo que se definió en funciones `r`.

$$\text{Moda} = \arg \max f(x)$$

- **Desviación estándar muestral y poblacional:** la muestral (`sd()` en R) divide entre $n - 1$ y se usa cuando los datos son una muestra de una población mayor; la poblacional divide entre N y se usa cuando los datos representan la población completa.

$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n - 1}} \quad \sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{\mu})^2}{N}}$$

- **MEDA (Mediana de Desviaciones Absolutas):** se definió como:

$$\text{MEDA} = \text{mediana}(|x_i - \text{mediana}(x)|)$$

Se utilizó como alternativa robusta a la desviación estándar en variables con asimetría extrema (conductividad, sodio), donde la desviación estándar clásica queda completamente distorsionada por los valores atípicos.

- **Coefficiente de variación (CV):** expresa la desviación estándar como porcentaje de la media, permitiendo comparar la dispersión relativa entre variables medidas en distintas unidades o con medias muy diferentes. Se define como:

$$CV = \frac{S}{\bar{x}} \times 100 \%$$

Un CV elevado (por encima del 100 %) indica alta variabilidad relativa y es señal de que la media es un estimador poco representativo. En R se calcula con `sd(x, na.rm=TRUE) / mean(x, na.rm=TRUE) * 100`.

- **Coefficiente de asimetría (skewness):** calculado con `skewness()` de la librería `moments`. Un valor positivo indica cola hacia la derecha; negativo indica cola hacia la izquierda.

$$\text{asimetría} = \frac{m_3}{S^3}, \quad \text{donde} \quad m_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^3$$

- **Curtois:** calculada con `kurtosis()` de `moments`. Mide qué tan pronunciado es el pico de la distribución y qué tan pesadas son sus colas en comparación con una distribución normal ($\kappa = 3$). Valores $\kappa > 3$ indican colas pesadas y presencia de valores extremos frecuentes.

$$\text{curtois} = \frac{\sum_{i=1}^n (x_i - \bar{X})^4}{nS^4} - 3$$

- **Asimetría de Bowley (cuartílica):** propuesta por Arthur Bowley a principios del siglo XX, esta medida cuantifica la asimetría únicamente a partir de los tres cuartiles Q_1 , Q_2 y Q_3 , sin utilizar ningún momento estadístico:

$$B = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1}$$

El numerador mide cuánto se aleja la mediana (Q_2) del punto medio del rango intercuartílico $(Q_1 + Q_3)/2$: si Q_2 está más cerca de Q_1 que de Q_3 , la distribución tiene más masa concentrada en la parte baja y una cola superior más extendida (asimetría positiva, $B > 0$). El denominador normaliza por el rango intercuartílico (RIC) para que el resultado sea siempre acotado entre -1 y $+1$.

- $B = 0$: distribución simétrica respecto a los cuartiles.
- $B > 0$: cola hacia la derecha (la mediana está por debajo del punto medio intercuartílico).
- $B < 0$: cola hacia la izquierda.
- $|B| < 0,10$: se considera prácticamente simétrico.

La ventaja decisiva frente al coeficiente de Fisher-Pearson es su **robustez**: al depender solo de cuartiles, el valor de B no cambia si los valores extremos se multiplican por 10 o se sustituyen por datos erróneos. Esto lo convierte en el estimador más adecuado para variables con distribuciones fuertemente sesgadas como la conductividad o el sodio, donde el coeficiente de Fisher-Pearson está completamente dominado por los valores atípicos. En R no existe una función nativa para B ; se definió en `funciones.r` como:

```
asimetria_bowley <- function(x) {
  x <- na.omit(x)
  q <- quantile(x, probs = c(0.25, 0.50, 0.75))
  (q[3] + q[1] - 2*q[2]) / (q[3] - q[1])
}
```

- **Curtosis de Moors (cuantílica):** introducida por Moors (1988), esta medida reemplaza los momentos de orden 4 por una combinación de *octiles* (cuantiles de orden $k/8$). Siendo $E_k = Q_{k/8}$ el k -ésimo octil:

$$M = \frac{(E_7 - E_5) + (E_3 - E_1)}{E_6 - E_2}$$

El numerador suma la anchura de las dos “colas externas” (desde E_1 a E_3 y desde E_5 a E_7); el denominador mide la anchura de la zona central (de E_2 a E_6). Una distribución con colas pesadas tiene colas externas anchas en relación al centro, produciendo un M alto.

- Distribución normal de referencia: $M \approx 1,23$.
- $M > 1,50$: colas más pesadas que la normal (leptocúrtica en sentido cuantílico).
- $M < 1,00$: colas más ligeras que la normal (platicúrtica en sentido cuantílico).

Al igual que Bowley, la curtosis de Moors es completamente robusta a valores atípicos porque depende solo de cuantiles. Esto permite contrastar sus resultados con la curtosis de exceso basada en momentos: si ambos coinciden en señalar colas pesadas, la conclusión es sólida; si difieren, significa que la curtosis de momentos está inflada por los valores extremos y no refleja el comportamiento del grueso de los datos. En R:

```
curtosis_moors <- function(x) {
  x <- na.omit(x)
  e <- quantile(x, probs = c(1/8,2/8,3/8,5/8,6/8,7/8))
  (e[6] - e[4] + e[3] - e[1]) / (e[5] - e[2])
}
```

- **Rango:** diferencia entre el valor máximo y mínimo. Se calculó para detectar valores sospechosos, como el mínimo de 0.0 en PH_LABORATORIO o el de 0°C en TEMPERATUR.

6.3. Visualizaciones

La selección del tipo de gráfico se basó en la naturaleza de las variables involucradas:

- **Histograma** (`geom_histogram`): se aplicó a variables numéricas continuas (PH_LABORATORIO, TEMPERATUR, CONDUCTIVIDAD) para visualizar cómo se distribuyen los valores. El número de intervalos se determinó con la regla de Sturges: $k = 1 + \log_2(n) \approx 1 + \log_2(320) \approx 9$. Para CONDUCTIVIDAD se aplicó escala logarítmica en el eje x (`scale_x_log10()`) debido a que su rango abarca casi seis órdenes de magnitud (0 a 278,000 $\mu\text{S}/\text{cm}$).
- **Diagrama de barras simple** (`geom_bar`): se aplicó a las variables categóricas CLASIFICACION_LIMPIA, OLOR_LIMPIO y ANIO.
- **Diagrama de barras apilado proporcional** (`geom_bar(position = "fill")`): se utilizó para comparar variables categóricas entre sí. Con `position = "fill"`, cada barra representa el 100 % de los manantiales de ese tipo, lo que permite comparar proporciones entre grupos de tamaños distintos.
- **Gráfico de torta** (`pie()`): se aplicó a OLOR_LIMPIO y CLASIFICACION_LIMPIA para mostrar la participación porcentual de cada categoría en el total.
- **Gráfico de dispersión** (`geom_point + geom_smooth`): se aplicó para explorar relaciones entre pares de variables numéricas: temperatura vs. pH, y sodio vs. conductividad. La línea de tendencia lineal (`method = "lm"`) permite ver la dirección de la relación.

7. Resultados y discusión

7.1. Variables numéricas

7.1.1. Distribución del pH

A partir del siguiente diagrama de tallo y hoja se puede observar la distribución completa del pH. El tallo corresponde a la parte entera del valor y las hojas a la primera cifra decimal, lo que permite identificar la concentración de datos y la presencia de valores extremos sin pérdida de información individual.

Tabla 1: Diagrama de tallo y hoja de la temperatura de los manantiales.

Tallo	Hojas
42	0
44	07
46	0
48	2
50	02
52	1
54	034509
56	99
58	4900023469
60	0113380001122334566777888899
62	00233445555666677788899000000112233445666667889
64	133345566666888899000000111355566889
66	00013345667890000133335567
68	000001226601346789
70	000003455666899900012234677
72	0000123444455578901244569
74	00013456801268
76	14703458
78	0705
80	00128
82	18000
84	03644
86	
88	342
90	04
92	4247
94	2
96	059

El diagrama confirma que la mayor concentración de valores se encuentra entre pH 5 y 8. Los valores cercanos a 0 son errores de registro identificados en la etapa de limpieza de datos.

Como se muestra en la fig. 1, la distribución del pH presenta asimetría negativa, con una media de 6,33 y una mediana de 6,51.

Distribución del pH en manantiales colombianos

Azul = Media = 6.81 | Amarillo = Mediana = 6.64 | $n = 287$




Figura 1: Distribución del pH en manantiales colombianos. Se indican la media (línea azul) y la mediana (línea amarilla).

La proximidad entre la media recortada (6,77) y la mediana sugiere que la influencia de valores extremos es limitada. Sin embargo, la presencia de valores atípicos bajos introduce un sesgo negativo ($\text{skewness} = -1,66$), evidenciando una cola más pronunciada hacia la izquierda. La curtosis (4,69) indica una distribución leptocúrtica, con mayor concentración de datos alrededor de la media.

El coeficiente de variación ($CV = 12,92\%$) indica una variabilidad moderada. Dado que el pH es una escala acotada (0–14) y la mayoría de los registros se concentra entre 5 y 8, un CV inferior al 30 % es consistente con una distribución relativamente homogénea en su núcleo central, a pesar de la presencia de valores extremos en los extremos de la escala.

Se identificaron varios registros con pH igual a 0, 1, 2 y 3, los cuales fueron considerados valores atípicos y excluidos del análisis. Por ejemplo, un pH de 0 corresponde a condiciones de acidez extrema propias de soluciones altamente concentradas o de ambientes geológicos excepcionales, como algunos drenajes ácidos de mina, y no es representativo de manantiales naturales debido a la capacidad amortiguadora de los sistemas hidrogeológicos [3]. Y según los estudios hidrogeoquímicos del Servicio Geológico Colombiano, algunos manantiales asociados a sistemas hidrotermales volcánicos presentan valores de pH inferiores a 4 debido a la interacción con gases magmáticos; sin embargo, el pH por sí solo no constituye un criterio suficiente para clasificarlos como manantiales volcánicos, ya que dicha clasificación requiere información geoquímica y geológica complementaria [4].

7.1.2. Temperatura del agua

El siguiente diagrama de tallo y hoja representa la distribución de la variable temperatura. El tallo corresponde a las decenas y las hojas a las unidades. Se emplean tallos divididos: la primera fila de cada tallo contiene hojas entre 0 y 4, y la segunda las hojas entre 5 y 9.

1	8
2	001112222223333334444444
2	5555555566666777777788888899999999
3	0000000111111111111222222222223333333333334444444
3	555555555666666666667777777777778888889999999
4	0000001111112222222222333444444444444
4	555555666666666667777777888888999999
5	00001111122222333333444444
5	55566678888888
6	0001122222333334
6	56789
7	0124444
7	666
8	11224
8	588
9	034

Figura 2: Diagrama de tallo y hoja para la variable temperatura.

A partir del diagrama se observa que la mayor concentración de valores se encuentra entre los 20 y 50 °C, con un pico notable en el rango de los 30–40 °C. La menor frecuencia de temperaturas elevadas (superiores a 70 °C) sugiere una distribución con asimetría positiva leve.

Como se muestra en la fig. 3, la distribución de la temperatura presenta una media de 41,75 °C y una mediana de 39 °C, lo que confirma que la mayoría de los puntos de muestreo corresponden a aguas termales.

Distribución de temperatura del agua

Rojo = Media = 42.41 | Naranja = Mediana = 39.3 | n = 315




Figura 3: Distribución de la temperatura del agua en manantiales colombianos. Se indican la media y la mediana.

La media recortada (41,37°C) es ligeramente menor que la media completa, lo que indica que los manantiales con temperaturas superiores a 80 °C inflan levemente el promedio. El coeficiente de asimetría positivo ($skewness = 0,687$) refleja una cola hacia la derecha. La curtosis (4,003) sugiere una distribución leptocúrtica, indicando colas relativamente pesadas y la existencia de valores extremos en el rango superior.

La desviación estándar (15,97) es considerablemente mayor que la desviación absoluta mediana (9), lo que evidencia la influencia de valores atípicos en la dispersión global.

El coeficiente de variación ($CV = 38,3\%$) indica una variabilidad moderada-alta. A diferencia de la conductividad y el sodio, en la temperatura el CV refleja una dispersión real asociada a la heterogeneidad geotérmica del territorio: desde manantiales hasta fumarolas hipertermales.

7.1.3. Conductividad eléctrica

Como se muestra en la fig. 4, la conductividad eléctrica presenta la mayor asimetría dentro del conjunto de variables analizadas. La media de 4,375,75 $\mu S/cm$ contrasta marcadamente con la mediana de 1,353,5 $\mu S/cm$, mientras que la media recortada al 5 % (2,199,23 $\mu S/cm$) evidencia que un pequeño conjunto de valores extremos influye de manera significativa sobre la media.

Distribución de conductividad eléctrica (escala log)

Escala logarítmica usada por
el rango extremo de valores | Media = 4762.72 | Mediana = 1624.5 | $n = 294$




Figura 4: Distribución de la conductividad eléctrica en manantiales colombianos en escala logarítmica.

El coeficiente de asimetría de Fisher(13,19) y la curtosis (206,3) indican una distribución fuertemente sesgada hacia la derecha y con colas extremadamente pesadas. Este comportamiento sugiere la presencia de un pequeño conjunto de manantiales con conductividades muy elevadas, posiblemente asociados a fumarolas o a influencia marina directa, alcanzando valores de hasta 278,000 $\mu\text{S}/\text{cm}$.

Sin embargo, al complementar el análisis con otros coeficientes de forma se obtiene una visión más completa de la distribución. El coeficiente de Bowley ($B = 0,214$) indica una asimetría positiva leve en la parte central de los datos. Al estar acotado entre -1 y 1 , este valor sugiere que la mayor parte de las observaciones no presenta una asimetría fuerte, aunque sí existe una ligera tendencia hacia valores más altos. Esto contrasta con el coeficiente de Fisher, que resulta mucho más sensible a valores extremos y, por tanto, amplifica el efecto de algunos datos muy grandes.

Por su parte, el coeficiente de Moors ($M = 2,081$), al compararse con el valor esperado en una distribución normal (aproximadamente 1,23), muestra que las colas de la distribución son más pesadas de lo habitual. Esto significa que hay más valores extremos de lo esperado, incluso si no son los más grandes del conjunto. En términos prácticos, esto sugiere que no todos los manantiales se comportan igual, sino que podría haber un grupo principal con baja mineralización y otro más pequeño con valores mucho más altos.

En conjunto, estos coeficientes no se deben interpretar por separado, sino como piezas complementarias. Fisher refleja el efecto de los extremos, Bowley describe el comportamiento de la parte central de los datos y Moors ayuda a entender qué tan pesadas son las colas. Juntos permiten entender mejor la forma real de la distribución.

Finalmente, el coeficiente de variación ($CV = 391,2\%$) confirma la extrema dispersión de la variable, evidenciando que la desviación estándar supera ampliamente la media. En este contexto, la desviación absoluta mediana ($1,141,5 \mu S/cm$) resulta una medida más robusta para describir la variabilidad típica del conjunto.

El uso de una escala logarítmica en el eje x resulta necesario para representar adecuadamente la distribución, ya que en escala lineal la mayor parte de las observaciones se concentraría en un rango muy reducido.

7.1.4. Sodio

Como se muestra en la fig. 5, el sodio presenta un comportamiento similar al de la conductividad eléctrica, lo cual es esperable dado que constituye el principal catión en aguas profundas y salinas. La media de $706,78 \text{ mg/L}$ es más de cuatro veces la mediana de $170,8 \text{ mg/L}$, evidenciando una distribución fuertemente sesgada.




Figura 5: Distribución de la concentración de sodio en manantiales colombianos.

Al recortar el 5 % de los valores extremos, la media disminuye a $293,59 \text{ mg/L}$, reduciendo la brecha con la mediana sin eliminarla completamente, lo que indica que la asimetría no depende exclusivamente de valores atípicos, sino que responde a una estructura intrínsecamente sesgada. El coeficiente de asimetría ($5,29$) y la curtosis ($31,68$) confirman la presencia de una cola derecha pronunciada y colas pesadas. La desviación absoluta mediana ($139,07 \text{ mg/L}$) resulta más representativa de la dispersión central que la desviación estándar ($2,187 \text{ mg/L}$).

El coeficiente de variación ($CV = 309,4\%$) confirma, al igual que en la conductividad, que la media es un estimador completamente inadecuado para esta variable. La fuerte correlación positiva entre sodio y conductividad confirma que los mismos manantiales con alta concentración de sodio son los que registran la mayor conductividad eléctrica, lo que explica por qué ambas variables presentan CVs igualmente extremos.

7.1.5. Calcio

Como se muestra en la fig. 6, el calcio presenta una asimetría moderada en comparación con el sodio y la conductividad. La media (98,4 mg/L) es superior a la mediana (57,4 mg/L), mientras que la media recortada (84,78 mg/L) reduce parcialmente esta diferencia.




Figura 6: Distribución de la concentración de calcio en manantiales colombianos.

El coeficiente de asimetría (2,51) y la curtosis (12,87) indican la presencia de una cola derecha, aunque menos pronunciada que en el caso del sodio. La desviación absoluta mediana (44,12 mg/L) sugiere que el 50 % central de los datos se concentra en un intervalo relativamente acotado alrededor de la mediana.

El coeficiente de variación ($CV = 118,6\%$) supera el umbral del 100 %, aunque de manera más moderada que la conductividad (391 %) y el sodio (309 %). Esta diferencia refleja la mayor homogeneidad del calcio: la presencia generalizada de rocas carbonatadas en el subsuelo colombiano produce concentraciones moderadas en la

mayoría de los manantiales, limitando el rango de los valores extremos. La moda (0,0) se explica por el hecho de que concentraciones menores a 0,1 mg/L suelen reportarse como no detectadas en los análisis de laboratorio.

7.1.6. Tabla de datos agrupados

Tabla 2: Resumen de medidas descriptivas para las variables analizadas.

Medida Estadística	pH	Temperatura	Conductividad	Calcio	Sodio
<i>Tendencia Central</i>					
Media	6,81	42,41	4 762,72	99,71	720,29
Media recortada (5 %)	6,77	41,37	2 483,03	85,95	306,94
Mediana	6,64	39,30	1 624,50	60,00	173,20
Moda	6,30	32,00	3 100,00	30,00	460,00
<i>Dispersión</i>					
Desv. estándar	0,88	15,20	17 807,86	116,89	2 206,03
MEDA	0,64	11,72	4 117,22	75,31	658,39
MAD	0,45	8,80	1 240,70	44,62	137,55
CV (%)	12,92	35,84	373,90	117,23	306,27
Rango	5,49	76,10	277 972,00	938,41	16 924,90
<i>Forma</i>					
Asimetría	0,80	1,01	12,70	2,51	5,24
Asimetría (Bowley)	—	—	0,17	—	—
Curtosis	4,70	3,86	190,66	12,93	31,09
Curtosis (Moors)	—	—	2,26	—	—

8. Análisis de variables categóricas

El conjunto de datos de manantiales colombianos contiene dos variables categóricas con significado geoquímico relevante: CLASIFICACIÓN (tipo de agua según cationes y aniones dominantes) y OLOR (descripción sensorial del agua en el punto de emergencia). A estas se suman dos variables categóricas *derivadas* que se construyen a partir de variables numéricas continuas: PH_CAT y TEMP_CAT. La categorización es necesaria porque transforma valores continuos en grupos con interpretación geoquímica directa, lo que permite construir tablas cruzadas y gráficos de barras comparativos que complementan los histogramas de la sección 7.1.

8.1. Tablas de frecuencias — una sola variable

8.1.1. Clasificación química del agua

La tabla 3 presenta las frecuencias absolutas y relativas de la variable CLASIFICACIÓN_LIMPIA.

Tabla 3: Frecuencias absolutas y relativas de la clasificación química del agua ($n = 290$).

Clasificación	Frecuencia	Porcentaje (%)
Bicarbonatada	135	46,6
Clorurada	68	23,4
Sulfatada	64	22,1
Clorurada - Bicarbonatada	8	2,8
Bicarbonatada - Sulfatada	5	1,7
Bicarbonatada - Clorurada	3	1,0
Clorurada - Sulfatada	2	0,7
Sulfatada - Bicarbonatada	2	0,7
Sulfatada Cálcica	2	0,7
Bicarbonatada - Sódica	1	0,3
Total	290	100,0

El tipo *Bicarbonatada* es el dominante con el 46,6 % del inventario, seguido por *Clorurada* (23,4 %) y *Sulfatada* (22,1 %). Juntas, estas tres clases concentran más del 92 % de los registros, lo que justifica que los análisis bivariados se restrinjan a ellas para mantener la legibilidad de los gráficos. La predominancia de agua bicarbonatada puede explicarse por la interacción entre aguas subterráneas ricas en CO_2 y la roca, proceso que favorece la formación de HCO_3^- a menores temperaturas [2]. Por otro lado, las aguas sulfatadas y cloruradas se asocian a sistemas volcánicos e hidrotermales [2].

8.1.2. Olor del agua

Tabla 4: Frecuencias absolutas y relativas del olor del agua ($n = 215$).

Olor	Frecuencia	Porcentaje (%)
Ausente	150	69,8
Leve	34	15,8
Fuerte	17	7,9
Moderado	8	3,7
H_2S	5	2,3
Otro	1	0,5
Total	215	100,0

El 69,8 % de los manantiales no presenta olor detectable. No obstante, el 10,2 % combinado de olor Fuerte más H_2S es geoquímicamente significativo, pues ambas categorías indican presencia de elementos como el sulfuro de hidrógeno. Sin embargo, el peso de la categoría ausente es significativamente más grande al de las categorías que presentan olor. Por tanto, se decidió agruparlos en dos categorías que se podrían denominar "binarias"; sin olor y con olor.

8.1.3. Categoría de pH

La variable PH_CAT se construye a partir de PH_LABORATORIO mediante tres intervalos: *Ácido* ($\text{pH} < 6,5$), *Neutro* ($6,5 \leq \text{pH} \leq 7,5$) y *Básico* ($\text{pH} > 7,5$) [1].

El 47,5 % de los manantiales presenta agua ácida, siendo la categoría más frecuente. La suma de ácidos y neutros alcanza el 86,3 % (276 manantiales), lo que indica que solo el 13,8 % presenta agua básica. Este resultado

Tabla 5: Frecuencias absolutas y relativas de la categoría de pH ($n = 320$).

Categoría de pH	Frecuencia	Porcentaje (%)
Ácido ($\text{pH} < 6,5$)	152	47,5
Neutro ($6,5 \leq \text{pH} \leq 7,5$)	124	38,8
Básico ($\text{pH} > 7,5$)	44	13,8
Total	320	100,0

es consistente con la mediana de $\text{pH} = 6,51$ reportada en las estadísticas descriptivas (section 7.1.1).

8.1.4. Categoría de temperatura

La variable TEMP_CAT divide la temperatura en tres rangos: *Fría* ($T < 20^\circ\text{C}$), *Tibia* ($20 \leq T \leq 50^\circ\text{C}$) y *Termal* ($T > 50^\circ\text{C}$). El umbral de 50°C corresponde al límite convencional entre agua geotérmica de baja y alta entalpía.

Tabla 6: Frecuencias absolutas y relativas de la categoría de temperatura ($n = 320$).

Categoría	Frecuencia	Porcentaje (%)
Fría ($T < 20^\circ\text{C}$)	7	2,2
Tibia ($20 \leq T \leq 50^\circ\text{C}$)	233	72,8
Termal ($T > 50^\circ\text{C}$)	80	25,0
Total	320	100,0

El 97,8 % de los manantiales corresponde a agua tibia o termal, lo que indica un predominio de sistemas con calentamiento subterráneo. Este resultado es consistente con el contexto geológico de Colombia, caracterizado por una intensa actividad tectónica y la presencia de sistemas volcánicos [2].

8.2. Tablas cruzadas — análisis bivariado

Las tablas cruzadas permiten analizar la relación entre dos variables categóricas. Para cada tabla se reportan: (i) frecuencias absolutas, (ii) proporciones por fila y (iii) proporciones por columna. En R, estas tablas se obtienen con la función `table()` y `prop.table()`.

8.2.1. pH categorizado $\times$ Temperatura categorizada

La tabla 7 cruza PH_CAT con TEMP_CAT. La hipótesis de trabajo es que los manantiales más calientes tienden a ser más ácidos, dado que a mayor temperatura aumenta la solubilidad de gases ácidos como CO_2 y H_2S .

Tabla 7: Frecuencias absolutas cruzadas de pH y Temperatura.

pH	Temperatura			Total
	Fría	Tibia	Termal	
Ácido	2	108	35	145
Neutro	0	88	36	124
Básico	0	36	7	43
Total	2	232	78	312

Tabla 8: Proporciones por **fila** (%) — pH $\times$ temperatura. Cada fila suma 100 %: indica cómo se distribuye la temperatura dentro de cada categoría de pH.

pH	Fría	Tibia	Termal
Ácido	1,4	74,5	24,1
Neutro	0,0	71,0	29,0
Básico	0,0	83,7	16,3

Tabla 9: Proporciones por **columna** (%) — pH $\times$ temperatura. Cada columna suma 100 %: indica cómo se distribuye el pH dentro de cada categoría de temperatura.

pH	Fría	Tibia	Termal
Ácido	100,0	46,6	44,9
Neutro	0,0	37,9	46,2
Básico	0,0	15,5	9,0

Las proporciones por columna de la tabla 9 muestran que en los manantiales termales ($T > 50^\circ\text{C}$) el 46,2 % presenta agua ácida, porcentaje similar al de los tibios (46,8 %). En cambio, en los manantiales fríos ($n = 2$) el 100 % es ácido, aunque el reducido tamaño de esta categoría limita la solidez de esa proporción. Destaca que en los manantiales termales la proporción de agua neutra (46,2 %) es casi tan alta como la de ácida, posiblemente asociada a una mayor interacción con rocas carbonatadas a mayor profundidad y temperatura.

8.2.2. pH categorizado $\times$ Clasificación química

Tabla 10: Tabla cruzada: pH $\times$ clasificación química (solo top 3). Frecuencias absolutas.

pH	Clasificación			Total
	Bicarbonatada	Clorurada	Sulfatada	
Ácido	48	26	45	120
Neutro	67	29	11	107
Básico	20	13	7	40
Total	135	68	64	267

Tabla 11: Proporciones por **fila** (%) — pH $\times$ clasificación. Cada fila suma 100 %: distribución del tipo de agua dentro de cada categoría de pH.

pH	Bicarbonatada	Clorurada	Sulfatada
Ácido	40,0	21,7	38,3
Neutro	62,6	27,1	10,3
Básico	50,0	32,5	17,5

Tabla 12: Proporciones por **columna** (%) — pH $\times$ clasificación. Cada columna suma 100 %: distribución del pH dentro de cada tipo de agua.

pH	Bicarbonatada	Clorurada	Sulfatada
Ácido	35,6	38,2	71,9
Neutro	49,6	42,6	17,2
Básico	14,8	19,1	10,9

La tabla 12 es la lectura más informativa: el 71,9 % de los manantiales sulfatados presenta agua ácida, frente al 38,2 % de los clorurados y el 35,6 % de los bicarbonatados. La Sulfatada es claramente la categoría más ácida, lo que refleja el proceso de oxidación de sulfuros metálicos que libera ácido sulfúrico y reduce el pH de forma drástica [2]. En cambio, la Bicarbonatada presenta la mayor proporción de agua neutra (49,6 %), coherente con su interacción con rocas carbonatadas que actúan como tampón del pH. La Clorurada ocupa una posición intermedia, con proporciones similares de ácida y neutra.

8.2.3. pH categorizado $\times$ Olor

Esta tabla cruzada conecta la acidez del agua con su olor, variable que actúa como indicador indirecto de la presencia de gases disueltos. La hipótesis es que los manantiales con olor a H_2S o “Fuerte” concentran mayor proporción de agua ácida, dado que el sulfuro de hidrógeno disuelto reduce el pH al ionizarse en solución acuosa.

Tabla 13: Tabla cruzada: pH $\times$ olor. Frecuencias absolutas ($n = 213$).

pH	Olor						Total
	Ausente	Fuerte	H_2S	Leve	Moderado	Otro	
Ácido	79	12	3	16	2	0	112
Neutro	53	2	1	12	6	1	75
Básico	18	3	1	6	0	0	28
Total	150	17	5	34	8	1	213

Tabla 14: Proporciones por **fila** (%) — pH $\times$ olor. Cada fila suma 100 %: indica cómo se distribuye el tipo de olor dentro de cada categoría de pH.

pH	Ausente	Fuerte	H_2S	Leve	Moderado	Otro
Ácido	70,5	10,7	2,7	14,3	1,8	0,0
Neutro	70,7	2,7	1,3	16,0	8,0	1,3
Básico	64,3	10,7	3,6	21,4	0,0	0,0

La tabla 15 muestra que el 70,6 % de los manantiales con olor Fuerte y el 60,0 % de los que presentan olor a H_2S son ácidos, proporciones mayores que el 52,7 % de los que no tienen olor. La tendencia es coherente con la hipótesis: los manantiales con gases sulfurosos disueltos tienden a presentar mayor acidez. La categoría Fuerte también incluye olores no necesariamente relacionados con H_2S , lo que puede explicar que no todos los manantiales de olor Fuerte sean ácidos. Esta asociación conecta con el resultado de la section 8.2.2: los manantiales sulfatados, que ya mostraban mayor acidez, son también los que concentran la mayoría de los olores intensos.

Tabla 15: Proporciones por **columna** (%) — pH $\times$ olor. Cada columna suma 100 %: indica cómo se distribuye el pH dentro de cada categoría de olor.

pH	Ausente	Fuerte	H ₂ S	Leve	Moderado	Otro
Ácido	52,7	70,6	60,0	47,1	25,0	0,0
Neutro	35,3	11,8	20,0	35,3	75,0	100,0
Básico	12,0	17,6	20,0	17,6	0,0	0,0

8.3. Gráficos de variables categóricas

Los gráficos de esta sección se generan con ggplot2 en R. Para las variables bivariadas se emplea `position = "fill"`, de modo que cada barra representa el 100 % de los manantiales de esa categoría y permite comparar proporciones entre grupos de tamaños muy distintos.

8.3.1. Distribución de una sola variable categórica

Clasificación de los manantiales. En la fig fig. 7 Se excluyeron las clasificaciones químicas con frecuencias absolutas residuales ($n < 10$, tales como Bicarbonatada-Sulfatada o Clorurada-Carbonatada) para evitar el ruido en la visualización y garantizar el análisis de los grupos más representativos. Trabajar con categorías con un soporte muestral extremadamente bajo incrementa la volatilidad de las proporciones calculadas y genera ruido.^{en} los gráficos, Complicando la realización de inferencias sólidas sobre el sistema hidrogeológico.




Figura 7: Frecuencia de cada tipo de agua según la clasificación química (CLASIFICACIÓN LIMPIA). La categoría *Bicarbonatada* es la más frecuente (46,6 %, véase tabla 3).

Olor del agua según la cantidad de manantiales En la fig. 8 se presenta la distribución de frecuencias absolutas para el tipo de olor en los manantiales analizados ($n = 213$). Se observa un marcado sesgo hacia la ausencia de olor, categoría que representa la moda clara de la variable con 150 manantiales (aproximadamente el 70,4 % del total de las observaciones). Por su parte, entre los manantiales que presentan algún tipo o intensidad de olor, la categoría de olor Leve es la más recurrente con 34 observaciones (16,0 %), seguida por la categoría Fuerte con 17 manantiales (8,0 %) y Moderado con 8 observaciones (3,8 %). Las categorías de menor frecuencia corresponden a la presencia explícita de gas H_2S con 5 registros (2,3 %) y la categoría Otro con un único registro (0,5 %). En cuanto a la interpretación hidrogeológica e implicaciones para el análisis bivariado, este comportamiento refleja que la presencia de olores intensos es un fenómeno localizado en un grupo reducido de manantiales. No obstante, aunque categorías como H_2S o Fuerte presentan un tamaño muestral no tan grande, su caracterización es hidrogeológicamente crítica, ya que la presencia de gases disueltos suele asociarse al recorrido de fluidos de origen profundo o sistemas térmicos con alta interacción de sulfatos.




Figura 8: Categoría de Olor según la cantidad de manantiales. La mayoría de manantiales no presenta olor, pero las aguas con compuestos ácidos son propensas a presentar olor. Véase tabla 4.

Caracterización del pH en los manantiales colombianos La fig. 9 ilustra la distribución de la variable derivada PH_CAT. La codificación de colores (rojo = ácido, amarillo = neutro, verde = básico) es consistente en todos los gráficos bivariados para facilitar la lectura cruzada entre figuras.




Figura 9: Distribución de manantiales por categoría de pH. Generado con PH-CAT según los umbrales de la tabla 5. Los porcentajes se indican sobre cada barra.

La fig. 10 muestra la distribución de los manantiales según la categoría de temperatura. Se observa una clara concentración en las categorías de agua tibia y termal, las cuales representan conjuntamente más del 95 % del total de observaciones.





Figura 10: Distribución de manantiales por categoría de temperatura. Más del 95 % de los manantiales corresponde a agua tibia o termal.

Como síntesis del análisis univariado, la Figura 11 permite contrastar la estructura de las dos variables principales. Mientras que la clasificación química muestra una distribución más repartida entre tres categorías dominantes (bicarbonatadas, cloruradas y sulfatadas), el olor presenta una dominancia absoluta de la categoría 'Ausente'. Esta diferencia de concentración es clave para entender por qué, en los análisis bivariados posteriores, el olor tiende a solaparse con tipos específicos de agua como la sulfatada.

Distribución porcentual
del olor del agua



Proporción de tipos de agua




Figura 11: Resumen visual de las proporciones generales. El panel superior muestra la hegemonía de manantiales sin olor (69,8 %), mientras que el panel inferior detalla la composición química, donde destaca el predominio de aguas bicarbonatadas (46,6 %). Esta visualización complementa los datos numéricos de la tabla 3 y la tabla 4.

8.3.2. Análisis bivariado entre variables categóricas

pH según temperatura. La fig. 12 representa en barras apiladas proporcionales la misma información de la tabla 9. Cada barra suma 100 % y permite comparar la composición de pH entre las tres categorías de temperatura. Del gráfico se puede decir que tanto en aguas tibias como termales, las categorías Ácido y Neutro concentran la

inmensa mayoría de las observaciones (sumando más del 84 % y 91 % del total de cada barra, respectivamente). Además los manantiales ácidos son sumamente similares entre aguas tibias y termales (aproximadamente 46,6 % y 44,9 %). Esto sugiere que el aumento térmico por sí solo no genera una mayor acidificación del agua. Las aguas ácidas pueden existir tanto a temperaturas moderadas como elevadas (por ejemplo, por la presencia de sulfatos o interacción con gases volcánicos/ácidos). Además, es posible ver que la categoría Neutro incrementa sensiblemente su presencia al pasar de agua tibia a termal, si tenemos en cuenta que las aguas termales normalmente se encuentran a gran profundidad, es posible que exista una interacción entre fluido y roca prolongada, neutralizando la acidez.




Figura 12: Relación entre pH y temperatura en los manantiales. Cada barra representa la distribución porcentual del pH dentro de cada categoría de temperatura.

pH según tipo de agua. La fig. 13 cruza PH.CAT con los tres tipos principales de agua. Cabe aclarar que de los manantiales fríos no es posible hacer afirmaciones, pues su tamaño muestral es de tan solo $n = 2$. Debido a este reducido tamaño muestral, las proporciones obtenidas no son representativas y no permiten realizar comparaciones confiables con las demás categorías.

Dejando de lado lo anterior, se observa un contraste hidrogeoquímico altamente diferenciado entre las tres familias. La categoría **Sulfatada** exhibe una marcada dominancia de la condición **Ácida**, abarcando más del 70 % de las observaciones de su grupo. En la práctica hidrogeológica, este comportamiento responde a la génesis de estas aguas, caracterizada por la oxidación de minerales sulfurados o la condensación de gases de origen volcánico/terrestre (H_2S).

En contraste, las aguas de tipo **Bicarbonatada** y **Clorurada** muestran una estructura composicional similar, donde prevalece la condición **Neutra** ($\approx 43\%$ y $\approx 42\%$, respectivamente) sumada a una presencia relevante de pH **Básico** ($\approx 15\%$ y $\approx 19\%$). Para las aguas bicarbonatadas, esto refleja la capacidad de neutralización frente a los

ácidos propia de los carbonatos; mientras que para las aguas cloruradas, confirma el estado de equilibrio químico fluido-roca típico de fluidos de circulación profunda.




Figura 13: Categoría de pH según tipo de agua (top 3 clasificaciones). La Sulfatada presenta el 71,9 % de sus manantiales en la categoría Ácido. Véase tabla 12.

pH según presencia de olor. La fig. 14 compara la concentración de pH en los manantiales que tienen presencia o ausencia de olor. Dado que la gran mayoría de los manantiales no presentaban olor y que las subcategorías de olor (fuerte, leve, moderado, H_2S) registraban frecuencias individuales reducidas, se reagrupó la variable en una clasificación binaria (Sin olor vs. Con olor). Esto permitió consolidar la muestra ($n = 213$) y evaluar con mayor solidez el comportamiento del pH. Como se observa en la fig. 14, la distribución relativa de pH (Ácido, Neutro, Básico) mantiene proporciones equivalentes independientemente de si el manantial presenta o no olor. Desde una perspectiva hidrogeoquímica, esto demuestra que la presencia de volátiles/gases en el punto de emersión no es un factor determinante ni restrictivo del pH del agua, descartando la hipótesis de que las aguas con olor perceptible estén sesgadas hacia valores ácidos. Por lo tanto, el olor no es un predictor definitivo o diagnóstico por sí solo para clasificar el pH de un manantial, pero sí actúa como un indicador indirecto que incrementa la probabilidad de acidez. Aunque más de la mitad de los manantiales sin olor también son ácidos (52,7 %), la presencia de olores intensos como H_2S (60,0 %) o Fuerte (70,6 %) eleva sustancialmente la proporción de aguas ácidas debido a la

presencia de gases disueltos.




Figura 14: Categoría de pH según olor del agua. Aquí se puede afirmar que el olor no es un factor determinante para asociarlo con un tipo de agua concreto. Esto descarta la hipótesis de que las aguas con más presencia de olor son las que tienen ácidos como el H_2S . Véase tabla 15.

9. Diagramas de Caja

Los diagramas de caja y bigotes constituyen una representación gráfica que resume la distribución de una variable cuantitativa mediante sus cuartiles, la mediana y la amplitud intercuartílica (IQR). Además, permiten identificar posibles valores atípicos, definidos como aquellas observaciones ubicadas por debajo de $Q_1 - 1.5 \times IQR$ o por encima de $Q_3 + 1.5 \times IQR$. Debido a ello, son una herramienta ampliamente utilizada para evaluar la dispersión, la simetría de los datos y la presencia de observaciones extremas.

9.0.1. Relación entre variables




Figura 15: Diagrama de caja del pH de los manantiales según el tipo de agua principal.

Comportamiento del pH según el tipo de agua. La Figura 15 presenta la distribución del pH de los manantiales según el tipo de agua principal (bicarbonatada, clorurada y sulfatada). En términos generales, las tres categorías muestran valores de pH concentrados alrededor de la neutralidad, con medianas comprendidas aproximadamente entre 6,3 y 6,8. Las aguas bicarbonatadas y cloruradas presentan medianas ligeramente superiores a las de las aguas sulfatadas.

En cuanto a la dispersión, las aguas sulfatadas exhiben un rango intercuartílico ligeramente mayor, lo que indica una mayor variabilidad en los valores centrales del pH. Por su parte, las aguas bicarbonatadas muestran varios valores atípicos hacia la parte superior de la distribución, alcanzando valores cercanos a 9,8, además de un valor atípico inferior alrededor de 4,8. En las aguas cloruradas se observa un comportamiento más homogéneo, con pocos valores atípicos, mientras que las aguas sulfatadas presentan un único valor extremo superior cercano a 9,6. Aunque las tres clasificaciones presentan medianas próximas a la neutralidad, la menor dispersión observada en las aguas cloruradas sugiere una mayor uniformidad en las condiciones hidrogeoquímicas que controlan el pH dentro de este grupo. En contraste, la mayor variabilidad y la presencia de valores atípicos en las aguas bicarbonatadas pueden asociarse tanto a la diversidad de procesos de interacción agua-roca que caracterizan este tipo de aguas como al mayor tamaño muestral de esta categoría dentro del conjunto de datos. En consecuencia, las diferencias observadas deben interpretarse como tendencias descriptivas y no como evidencia de diferencias hidrogeoquímicas.




Figura 16: Distribución de la temperatura según el tipo de agua principal. Se observa que las aguas cloruradas presentan una mediana de temperatura ligeramente superior a las bicarbonatadas y sulfatadas.

Distribución de la temperatura según el tipo de agua principal. La Figura 16 presenta la distribución de la temperatura (°C) según el tipo de clasificación química del agua. En términos de tendencia central, las aguas de clasificación **Clorurada** muestran la mediana más elevada ($\approx 44^\circ\text{C}$), con un límite inferior del rango intercuartílico ($Q_1 \approx 36^\circ\text{C}$) sensiblemente superior al de los demás grupos. En contraste, las familias **Bicarbonatada** y **Sulfatada** registran medianas similares y más bajas ($\approx 36^\circ\text{C}$).

Respecto a la dispersión, la categoría **Sulfatada** exhibe el mayor rango intercuartílico y la mayor amplitud total (con temperaturas que abarcan desde $\approx 18^\circ\text{C}$ hasta más de 85°C), evidenciando que los procesos de sulfatación ocurren en un amplio espectro de condiciones térmicas.

Asimismo, se identifican valores atípicos (*outliers*) en las aguas **Bicarbonatadas** ($> 80^\circ\text{C}$) y **Cloruradas** ($\approx 90^\circ\text{C}$), correspondientes a manantiales denominados hipertermales, que se alejan del comportamiento promedio.

Desde una perspectiva hidrogeoquímica, la mayor temperatura mediana observada en la familia **Clorurada** ($\approx 44^\circ\text{C}$) refleja un tiempo de residencia extenso y una de circulación profunda, favorecido por el gradiente geotérmico de la zona. El cloro actúa como un ion conservativo característico de sistemas hidrotermales profundos.

En contraste, la menor temperatura general de las aguas **Bicarbonatadas** es consistente por su interacción con rocas superficiales. Por su parte, el amplio rango térmico de la familia **Sulfatada** (de 18°C a $> 85^\circ\text{C}$) evidencia la coexistencia de diferentes sistemas hidrogeológicos.

10. Correlación entre variables numéricas

Con el propósito de evaluar el grado de asociación lineal entre las variables cuantitativas del conjunto de datos, se emplearon distintos coeficiente de correlación como el de Pearson, Kendall y Spearman. Estos coeficientes están normalizados, por lo que toman valores entre -1 y 1 , donde valores cercanos a 1 indican una asociación lineal positiva fuerte, valores próximos a -1 representan una asociación lineal negativa fuerte y valores cercanos a cero sugieren ausencia de relación. Se utilizaron diagramas de dispersión para visualizar el comportamiento conjunto de las variables y verificar la forma de la relación observada teniendo en cuenta los análisis y los resultados de las secciones previas.

10.1. Diagramas de correlación bajo el modelo de Pearson




Figura 17: Diagrama de dispersión entre la concentración de sodio y la conductividad del agua. La línea roja representa el ajuste lineal obtenido mediante el coeficiente de correlación de Pearson. Se observa una tendencia positiva, lo que indica que, a mayores concentraciones de sodio corresponden mayores valores de conductividad.

Correlación entre Sodio y Conductividad Eléctrica Para la fig. 17 se seleccionó el par de variables **Sodio** y **Conductividad Eléctrica** para evaluar el grado en que este catión mayoritario influye la mineralización total del agua en el sistema de manantiales evaluado. La conductividad eléctrica actúa como un indicador directo del total de sólidos disueltos.

La Figura 17 muestra una marcada tendencia lineal positiva entre la concentración de sodio y la conductividad eléctrica. El coeficiente de correlación de Pearson obtenido ($r=0.9543$) evidencia una asociación lineal muy fuerte

entre ambas variables, indicando que los manantiales con mayores concentraciones de sodio tienden a presentar también mayores valores de conductividad.

Este comportamiento es consistente con la naturaleza de la conductividad eléctrica, la cual depende de la concentración total de iones disueltos en el agua. Dado que el sodio constituye uno de los principales cationes presentes en muchos sistemas hidrogeoquímicos, un incremento en su concentración contribuye significativamente al aumento de la conductividad. Aunque eso no excluye la incidencia de otros iones como el calcio, magnesio, bicarbonato, sulfato y cloruro, que también participan en este proceso. Los resultados obtenidos sugieren que el sodio es un buen indicador de la mineralización del agua en los manantiales analizados.




Figura 18: Diagrama de dispersión entre la concentración de calcio y la conductividad del agua.

Correlación entre Calcio y Conductividad eléctrica. En la fig. 18, a diferencia del comportamiento observado con el sodio, la relación entre el **Calcio** y la **Conductividad Eléctrica** presenta una correlación lineal débil, con un coeficiente de Pearson de $r \approx 0,215$.

Este comportamiento es esperable, ya que la conductividad eléctrica depende de la concentración total de especies iónicas presentes en el agua. Aunque el calcio constituye uno de los principales cationes en aguas naturales, su concentración por sí sola no determina totalmente la conductividad, la cual también está influenciada por otros iones como sodio, magnesio, bicarbonatos, sulfatos y cloruros. Asimismo, se observa un valor extremo correspondiente a un manantial con concentraciones excepcionalmente elevadas de calcio y conductividad. Aunque este registro influye en la recta de regresión, la mayoría de las observaciones permanecen concentradas en valores bajos y muestran una relación lineal casi inexistente.

Diagrama 3D: Sodio vs Calcio vs Conductividad | n = 288




Figura 19: Diagrama de dispersión entre las concentraciones de sodio, calcio y la conductividad del agua.

Dispersión en tres dimensiones: Sodio, Calcio y Conductividad eléctrica. Para explorar la relación conjunta entre los dos cationes dominantes y la mineralización global del agua, se construyó un diagrama de dispersión tridimensional con sodio (mg/L), calcio (mg/L) y conductividad eléctrica ($\mu S/cm$) como ejes. Dado que las tres variables presentan distribuciones fuertemente asimétricas con rangos de varios órdenes de magnitud, sodio de 0.1 a 20,000 mg/L , conductividad de 10 a 278,000 $\mu S/cm$, se aplicó transformación logarítmica (base 10) en los tres ejes. Esta transformación permite visualizar simultáneamente el grueso de los manantiales y los valores extremos sin que unos anulen a los otros visualmente. El análisis previo de los datos reveló que los manantiales con conductividad superior a 19,000 $\mu S/cm$ se concentran geográficamente en torno a las coordenadas 5.76°N, 73.1°O, correspondientes al sistema geotérmico de Paipa-Iza (Boyacá). Este sistema, ampliamente documentado por el Servicio Geológico Colombiano se caracteriza por aguas sulfatadas sódicas de origen magmático, calentadas por un volcán extinto que hizo erupción por última vez hace aproximadamente un millón de años. La alta concentración de sodio (entre 6,000 y 16,900 mg/L) y la conductividad extrema de estos manantiales son coherentes con la naturaleza del sistema: el agua circula a gran profundidad disolviendo sales sulfatadas y cloruradas antes de emerger a temperaturas de hasta 70°C. Adicionalmente, se identificó un segundo punto atípico (ID 1283, coordenadas 6.13°N, 72.3°O) con conductividad de 278,000 $\mu S/cm$ y calcio de 939 mg/L , cuyas características corresponden a una salmuera o agua de formación, geoquímicamente distinta al sistema de Paipa.

En el gráfico, ambos grupos aparecen diferenciados mediante color y símbolo del resto de los manantiales. La nube principal muestra una tendencia positiva entre sodio, calcio y conductividad, lo que confirma que la mineralización global del agua, medida como conductividad, está efectivamente, controlada por la concentración de estos cationes mayoritarios.

10.1.1. Matrices de covarianza y Correlación

Para evaluar de manera integral las interrelaciones entre los diferentes parámetros fisicoquímicos e iones mayoritarios presentes en los manantiales, se construyeron las matrices de **covarianza** y de **correlación de Pearson**.

A diferencia del análisis bivariado individual, la aproximación matricial permite identificar patrones globales de asociación, agrupaciones iónicas y posibles mecanismos hidrogeoquímicos comunes que gobiernan la composición del sistema.

- **Matriz de Covarianza:** Proporciona una medida de la variabilidad conjunta entre las variables en sus unidades originales. Permite identificar qué pares de variables presentan la mayor dispersión y co-variación absoluta en el conjunto de datos.
- **Matriz de Correlación:** Al estandarizar las covarianzas mediante las desviaciones estándar de cada parámetro, escala los valores en un rango acotado $[-1, 1]$. Esto facilita la comparación directa entre variables de distintas magnitudes (por ejemplo, pH, temperatura y concentraciones iónicas en mg/L) e identifica la fuerza y dirección de la asociación lineal.

A continuación, se presentan las representaciones gráficas de ambas matrices, acompañadas de su respectiva interpretación hidrogeoquímica.




Figura 20: Matriz de correlación de Pearson para Sodio, Calcio y Conductividad Eléctrica.

Matriz de Correlación de Pearson. La Figura 20 ilustra la matriz de correlación de Pearson para las variables Sodio, Calcio y Conductividad Eléctrica. El análisis conjunto de estos tres parámetros permite resumir la estructura hidrogeoquímica del sistema:

- **Sodio vs. Conductividad:** Presenta una correlación lineal positiva muy fuerte ($r = 0,9543$), indicando que los manantiales con mayor concentración de sodio tienden a presentar también una mayor conductividad eléctrica. Este resultado es consistente con el hecho de que el sodio es uno de los principales iones disueltos que contribuyen a la mineralización del agua.
- **Calcio vs. Conductividad:** Presenta una correlación positiva débil ($r \approx 0,24$), lo que confirma que la concentración de calcio, por sí sola, no explica las variaciones de la conductividad. Esto se debe a que la conductividad depende de la concentración total de otros iones disueltos y no únicamente del calcio.
- **Sodio vs. Calcio:** Permite evaluar la relación entre ambos cationes presentes en el agua. Las diferencias observadas entre sus concentraciones pueden estar asociadas a la evolución química que experimentan los manantiales durante su circulación por el subsuelo.




Figura 21: Matriz de covarianza para Sodio, Calcio y Conductividad Eléctrica.

Matriz de Covarianza. La matriz de covarianza (Figura 21) permite analizar la variabilidad conjunta de los tres parámetros en sus unidades originales.




Figura 22: Matriz de dispersión, histogramas y coeficientes de correlación en escala logarítmica para Sodio, Calcio y Conductividad.

Matriz de diagramas de dispersión. Al aplicar la transformación logarítmica (log) a las variables de **Sodio**, **Calcio** y **Conductividad Eléctrica**, se corrigió la asimetría de los datos y el efecto de los valores atípicos extremos:

- **Normalización de las distribuciones:** Los histogramas de la diagonal principal reflejan que la transformación logarítmica suavizó las escalas, permitiendo una interpretación lineal más clara de las relaciones entre variables.
- **Recuperación de la relación del Calcio:** A diferencia del análisis con datos crudos, la relación entre $\log(\text{Calcio})$ y $\log(\text{Conductividad})$ muestra una fuerte correlación positiva ($r = 0,734, p < 0,001$). Esto confirma que la concentración de calcio acompaña el incremento de la mineralización total del agua.
- **Dominancia del Sodio:** El par $\log(\text{Sodio})$ – $\log(\text{Conductividad})$ mantiene la asociación más alta ($r = 0,883, p < 0,001$), ratificando que el sodio es el principal motor de la salinidad en los manantiales estudiados.


10.2. Correlación de Spearman y Kendall

Dado que las variables numéricas analizadas presentan distribuciones fuertemente asimétricas con valores atípicos extremos se observó lo limitado que es el coeficiente de Pearson, cuyo cálculo asume normalidad y es sensible a outliers. Utilizar los coeficientes de Spearman y Kendall resulta más efectivo, pues ambos están basados en rangos y por tanto son robustos frente a valores extremos.

El coeficiente de Spearman es el estándar para datos fisicoquímicos con esta estructura, mientras que Kendall se incluye como verificación de robustez: si ambos coeficientes coinciden en signo y magnitud aproximada, la correlación detectada es sólida independientemente del método.

Las correlaciones no significativas al nivel $\alpha = 0,05$ se marcan con una X en el gráfico, indicando que no hay evidencia suficiente para afirmar que existe relación entre esas variables en la población.

Debido a la presencia de asimetría en las distribuciones de los parámetros fisicoquímicos y a la existencia de valores atípicos (como se evidenció en los diagramas de dispersión), se evaluó la asociación no paramétrica mediante los coeficientes de **Spearman** (ρ_s) y **Kendall** (τ). A diferencia del coeficiente de Pearson, estos métodos evalúan relaciones basadas en rangos, siendo insensibles a transformaciones no lineales y a datos extremos.



(a) Matriz de correlación de Spearman.

(b) Matriz de correlación de Kendall.

Figura 23: Matrices de correlación no paramétrica ($n = 287$). Las celdas marcadas con 'X' indican correlaciones no significativas ($p > 0,05$).

Contraste con Pearson e interpretación hidrogeoquímica de los coeficientes de correlación de Kendall y Tau Los resultados obtenidos mediante los coeficientes de Spearman y Kendall muestran un comportamiento similar al observado con el coeficiente de Pearson para algunas variables, aunque permiten apreciar mejor las relaciones cuando existen valores extremos o distribuciones no normales.

- **Calcio y conductividad.** Mientras que la correlación de Pearson indicó una relación lineal débil, los coeficientes de Spearman ($r_s = 0,73$) y Kendall ($\tau = 0,54$) muestran una asociación positiva mucho más fuerte. Esto sugiere que, aunque la relación entre ambas variables no es completamente lineal, los manantiales con mayor concentración de calcio tienden, en general, a presentar también una mayor conductividad.
- **Sodio y conductividad.** Esta relación continúa siendo la más fuerte en los tres métodos de correlación. Tanto Pearson como Spearman y Kendall indican que los manantiales con mayor concentración de sodio presentan también una mayor conductividad eléctrica, resultado consistente con el aporte del sodio al contenido total de sales disueltas en el agua.
- **Temperatura y pH.** En ambos coeficientes no paramétricos se observan correlaciones bajas o cercanas a cero con la mayoría de las variables químicas. Además, algunas relaciones no fueron estadísticamente significativas, lo que indica que, dentro del conjunto de datos analizado, no existe evidencia suficiente para afirmar una asociación entre estas variables.

11. Análisis de distancias y agrupamiento

11.1. Criterios de agrupamiento

El análisis de agrupamiento jerárquico (*hierarchical clustering*) permite identificar subconjuntos naturales de manantiales con perfiles fisicoquímicos similares sin imponer previamente el número de grupos. A diferencia de los

análisis univariados y bivariados presentados anteriormente, el agrupamiento considera simultáneamente las cinco variables numéricas principales del estudio, lo que permite obtener una clasificación más completa y geológicamente coherente de los manantiales colombianos.

11.1.1. Selección de variables

Se incluyeron las cinco variables numéricas con mayor cobertura de datos y significado directo: PH, LABORATORIO, TEMPERATUR, CONDUCTIVIDAD, SODIO y CALCIO. Cada variable aporta una dimensión diferente al perfil del manantial: el pH describe su acidez geoquímica; la temperatura indica la profundidad e influencia magmática; la conductividad refleja la mineralización total del agua; el sodio caracteriza las sales de origen profundo o volcánico; y el calcio describe la disolución de rocas carbonatadas en el recorrido subterráneo del agua.

La inclusión de las cinco variables juntas permite distinguir manantiales que con menos variables parecerían idénticos. Por ejemplo, dos manantiales con igual conductividad y temperatura pero distinta relación sodio/calcio tienen orígenes geológicos diferentes: uno proviene de rocas carbonatadas y el otro de ambientes volcánicos. Esta distinción solo es posible al considerar el perfil completo de cinco variables.

Se excluyeron los registros con al menos un valor faltante en alguna de las cinco variables, así como los manantiales con temperatura igual a cero (valores sospechosos).

11.1.2. Estandarización

Antes de calcular cualquier distancia, las variables se estandarizaron a media cero y desviación estándar uno mediante la función `scale()` de R:

$$z = \frac{x - \bar{x}}{S}$$

donde x es el valor de la variable, $\bar{x}$ es la media de la variable y S es desviación estándar muestral.

Este paso es indispensable porque las variables tienen escalas completamente diferentes: la conductividad alcanza valores de hasta 278,000 $\mu\text{S}/\text{cm}$ mientras que el pH solo va de 0 a 14. Sin estandarizar, la conductividad dominaría completamente el cálculo de distancias y los grupos obtenidos reflejarían casi exclusivamente esa variable, ignorando el pH, la temperatura y los demás iones.

11.1.3. Métricas de distancia

Se calcularon dos matrices de distancia para evaluar la robustez de los grupos obtenidos. La **distancia Manhattan** suma las diferencias absolutas entre las variables estandarizadas de dos manantiales i y j :

$$d_{\text{Manhattan}}(i, j) = \sum_{k=1}^5 |z_{ik} - z_{jk}|$$

La **distancia Canberra** pondera cada diferencia absoluta por la suma de los valores absolutos, haciéndola más sensible a diferencias en variables con valores pequeños:

$$d_{\text{Canberra}}(i, j) = \sum_{k=1}^5 \frac{|z_{ik} - z_{jk}|}{|z_{ik}| + |z_{jk}|}$$

Ambas métricas son robustas frente a valores atípicos, a diferencia de la distancia Euclidiana, que eleva al cuadrado las diferencias y amplifica el efecto de los outliers (especialmente problemático en este caso, pues la conductividad y el sodio presentan curtosis muy altas).

11.1.4. Agrupamiento jerárquico y dendrogramas

Con cada matriz de distancia se aplicó el método de agrupamiento jerárquico con enlace completo (*complete linkage*), que define la distancia entre dos grupos como la distancia máxima entre cualquier par de sus elementos:

$$d(A, B) = \max_{i \in A, j \in B} d(i, j)$$

Este criterio tiende a producir grupos compactos y bien separados, lo que facilita la interpretación geológica de los conglomerados resultantes. El resultado del algoritmo se representa mediante un dendrograma, que muestra jerárquicamente cómo se van fusionando los manantiales y grupos a medida que aumenta la distancia de unión.




Figura 24: Dendrogramas de agrupamiento jerárquico con enlace completo para las distancias Manhattan (izquierda) y Canberra (derecha). El eje vertical indica la distancia a la que se fusionan los grupos. Las etiquetas de los manantiales se omiten por legibilidad.

Los resultados de los dendrogramas para cada distancia se aprecian en la Figura 24. El gráfico de Manhattan exhibe dos saltos notables en su eje vertical: el primero a una altura de 10 y el segundo cercano a 21. El espacio más notorio, comprendido entre los niveles 10 y 21, muestra que la última unión supuso un aumento considerable de la distancia, sugiriendo que un componente se diferencia drásticamente de los demás. Asimismo, en el salto anterior (entre 5 y 10) se nota la delimitación de un segundo bloque con rasgos propios. Con este criterio, se fijó el número de grupos en $k = 3$.

En el dendrograma de Canberra la progresión resulta más uniforme y carece de cortes bruscos, lo que significa que esta métrica reparte las desviaciones de forma equitativa entre las fuentes de agua. A pesar de esta diferencia, la organización en tres agrupaciones permanece detectable, validando que dicha clasificación es una propiedad auténtica de los datos y no un efecto artificial de la métrica.

11.1.5. Elección del número de grupos

Como se mencionó anteriormente, el número de grupos k se determinó visualmente a partir de la altura de corte de los dendrogramas, buscando el nivel en el que existe un salto notable en la distancia de fusión lo que

indica que grupos naturalmente separados comienzan a unirse forzosamente. Con base en este criterio se seleccionó $k = 3$, que produce grupos interpretables desde el punto de vista geológico.

11.1.6. Perfil de los grupos

Una vez asignados los $k = 3$ grupos mediante la función `cutree()`, se calculó el perfil mediano de cada grupo en las cinco variables. Se usó la mediana en lugar de la media por su robustez frente a los valores atípicos que persisten dentro de cada grupo.

Tabla 16: Perfil mediano de los tres grupos de manantiales (distancia Manhattan, enlace completo).

Grupo	n	pH	Temp. (°C)	Cond. ($\mu\text{S}/\text{cm}$)	Sodio (mg/L)	Calcio (mg/L)
Grupo 1	257	6.64	38.0	1360	170.0	51.3
Grupo 2	6	6.90	53.6	43800	13388.0	88.5
Grupo 3	3	6.51	46.9	27600	6412.0	100.0




Figura 25: Diagrama de dispersión de temperatura versus conductividad del agua para los grupos asignados por la distancia Manhattan

Caracterización de los grupos. La Figura 25 presenta el diagrama de dispersión de temperatura versus conductividad con los manantiales coloreados según el grupo asignado mediante la distancia Manhattan y enlace

completo. La Tabla 16 sintetiza el perfil mediano de cada conglomerado, evidenciando firmas geoquímicas e iónicas claramente diferenciadas:

Grupo 1 ($n = 257$) agrupa la gran mayoría de los manantiales del estudio ($\sim 89,5\%$), caracterizado por valores medianos de temperatura de $38,0^{\circ}\text{C}$, una conductividad eléctrica de $1360\ \mu\text{S}/\text{cm}$, pH neutro (6,64) y concentraciones moderadas de sodio ($170,0\ \text{mg}/\text{L}$) y calcio ($51,3\ \text{mg}/\text{L}$). Representa el perfil típico de los manantiales regionales de recarga local y flujo corto, con mineralizaciones dentro de rangos normales y sin influencias geotérmicas o de salmueras extremas.

Grupo 2 ($n = 6$) concentra el grupo con las temperaturas y grados de mineralización más elevados del conjunto de datos, con una mediana de temperatura de $53,6^{\circ}\text{C}$ y una conductividad de $43800\ \mu\text{S}/\text{cm}$. Este grupo se destaca por un contenido masivo de sodio (mediana de $13388,0\ \text{mg}/\text{L}$) y niveles de calcio de $88,5\ \text{mg}/\text{L}$. Corresponde a sistemas de origen profundamente evolucionado e influencia hidrotermal (asociado a sectores de alta actividad geotérmica como el sistema Paipa-Iza), donde la elevada salinidad y temperatura responden a la circulación profunda y al arrastre de sodio. La capacidad del algoritmo para aislar este grupo confirma la solidez de las variables seleccionadas.

Grupo 3 ($n = 3$) agrupa un conjunto muy reducido de fuentes térmicas con una temperatura mediana de $46,9^{\circ}\text{C}$, una conductividad eléctrica de $27600\ \mu\text{S}/\text{cm}$ y un pH de 6,51. Aunque presentan una mineralización total menor a la del Grupo 2, destacan por una relación catiónica distinta, con concentraciones medianas de sodio de $6412,0\ \text{mg}/\text{L}$ y los niveles más altos de calcio de todo el conjunto ($100,0\ \text{mg}/\text{L}$). El algoritmo los aisló como un conjunto de aguas fuertemente mineralizadas con una respuesta iónica diferenciada respecto al resto de la muestra.

11.2. Rostros de Chernoff

Los rostros de Chernoff son una técnica de visualización multivariada que codifica variables numéricas en rasgos faciales, aprovechando la capacidad innata del sistema visual humano para detectar diferencias entre rostros. Cada rostro representa el perfil mediano de un grupo en las cinco variables analizadas: pH, temperatura, conductividad, sodio y calcio. Con cinco variables cada rasgo facial tiene un significado específico tamaño de ojos, curvatura de la boca, forma de la nariz, entre otros lo que hace la comparación más rica que con solo tres variables.

Rostros de Chernoff | n = 266




Figura 26: Rostros de Chernoff para los tres grupos de manantiales. Cada rostro representa el perfil mediano del grupo en pH, temperatura, conductividad, sodio y calcio. Las diferencias faciales reflejan diferencias simultáneas en las cinco variables fisicoquímicas.

Los rostros de Chernoff (Figura 26) hacen visualmente evidente la separación entre grupos que las tablas describen numéricamente, mapeando cada variable en un rasgo facial específico:

- **Conductividad Eléctrica (estructura del rostro, ancho de ojos y ancho de nariz):** Domina la geometría general de la cara. El **Grupo 2** y el **Grupo 3** presentan rostros sensiblemente más ensanchados y robustos en comparación con el **Grupo 1**, reflejando visualmente sus elevadas magnitudes de mineralización total frente al perfil de baja salinidad del grupo mayoritario.
- **Sodio (altura de la boca, altura del cabello y ancho de la oreja):** Modifica la prominencia del cabello y la boca. El **Grupo 2**, con su valor mediano extremo de sodio (13388,0 mg/L), exhibe los rasgos del cabello más altos y destacados de la figura, permitiendo diferenciarlo instantáneamente de las aguas con contenido sódico moderado.
- **Temperatura (ancho de la cara, altura de los ojos y altura de la nariz):** Rige el tamaño de las facciones centrales (ojos y nariz). Los **Grupos 2 y 3** (con medianas de 53,6°C y 46,9°C, respectivamente) muestran rasgos oculares y nasales notablemente más elongados que el **Grupo 1** (38,0°C), lo que permite identificar a simple vista su firma de origen geotérmico o hidrotermal profundo.
- **Calcio (ancho de la boca, ancho del cabello y altura de la oreja):** Define el marco lateral del rostro. El **Grupo 3** (100,0 mg/L) y el **Grupo 2** (88,5 mg/L) presentan orejas más elevadas y un cabello más ancho en comparación con el **Grupo 1** (51,3 mg/L), evidenciando el incremento en la concentración de este catión a medida que aumenta la evolución iónica.
- **pH (altura de la cara, sonrisa y estilo del cabello):** Rige la curvatura de la boca y la altura facial. Dado que los tres grupos presentan valores medianos de pH muy cercanos y cercanos a la neutralidad (6,64, 6,90

y 6,51), los rasgos asociados a esta variable (como la expresión de la sonrisa) permanecen relativamente homogéneos entre los rostros, confirmando que el pH no es un factor determinante en la separación de los conglomerados.

En conclusión, el **Grupo 3** presenta el rostro más atípico y diferenciado de la figura debido a su respuesta conjunta en conductividad y sodio, mientras que el **Grupo 2** contrasta con el **Grupo 1** principalmente a través de las facciones asociadas a la temperatura y al sodio extremo. La principal ventaja de los rostros de Chernoff sobre un diagrama de dispersión convencional es que permiten sintetizar y comparar estas cinco dimensiones hidrogeoquímicas de forma simultánea en una sola figura, superando la limitación bivariada de los *scatterplots*.

12. Medidas de Similitud

12.1. La Distancia de Gower

En el análisis de datos con variables de naturaleza mixta las métricas de distancia clásicas como la distancia Euclídea o la de Manhattan resultan inaplicables, ya que presuponen que todas las variables están medidas en la misma escala numérica continua. La elección del coeficiente de Gower sobre otras métricas de similitud categórica (tales como la coincidencia simple o el índice de Jaccard) se fundamenta en su versatilidad metodológica:

- **Flexibilidad de tipos de variables:** A diferencia de métricas como Jaccard o SMC, diseñadas de forma exclusiva para matrices binarias homogéneas, Gower permite evaluar simultáneamente atributos nominales no ordenados, variables ordinales y binarias asimétricas sin necesidad de transformar o binarizar artificialmente el dataset.
- **Control de ausencias no informativas:** Evita la sobreestimación de la similitud entre manantiales por la coincidencia de ausencias en características raras (como la presencia de emanaciones gaseosas), un sesgo frecuente cuando se emplea el coeficiente de coincidencia simple (*SMC*).
- **Acotamiento y comparabilidad:** Al estructurar la similitud en el intervalo estricto $[0, 1]$, proporciona un marco estandarizado que representa directamente la proporción de coincidencia de atributos.

La **distancia de Gower** resuelve este problema definiendo una disimilitud normalizada d_{ij} entre dos observaciones i y j como el promedio ponderado de las disimilitudes parciales calculadas variable a variable:

$$d_{ij} = \frac{\sum_{k=1}^p w_{ijk} \delta_{ijk}}{\sum_{k=1}^p w_{ijk}} \quad (41)$$

donde:

- p es el número total de variables consideradas.
- w_{ijk} es un peso binario que vale 1 si la comparación entre i y j en la variable k es válida (ambos valores presentes), y 0 en caso contrario. Esto permite manejar datos faltantes de forma natural.
- δ_{ijk} es la disimilitud parcial en la variable k , definida según el tipo de variable:

Variables categóricas nominales. La disimilaridad parcial toma valor 0 si las dos observaciones pertenecen a la misma categoría, y 1 si pertenecen a categorías distintas:

$$\delta_{ijk} = \begin{cases} 0 & \text{si } x_{ik} = x_{jk} \\ 1 & \text{si } x_{ik} \neq x_{jk} \end{cases} \quad (42)$$

El resultado final d_{ij} está acotado en el intervalo $[0, 1]$, donde $d_{ij} = 0$ indica que las dos observaciones son idénticas en todas las variables consideradas, y $d_{ij} = 1$ indica la máxima disimilaridad posible.

12.2. De distancia a similitud

Dado que $d_{ij} \in [0, 1]$, la transformación

$$s_{ij} = 1 - d_{ij} \quad (43)$$

produce directamente una **matriz de similitud** S cuyos elementos $s_{ij} \in [0, 1]$ son interpretables de forma intuitiva: $s_{ij} = 1$ indica identidad completa entre los manantiales i y j , y $s_{ij} = 0$ indica la máxima disimilaridad posible. Esta propiedad convierte a s_{ij} en una medida de similitud genuina, análoga a un coeficiente de concordancia, pero aplicable a mezclas de variables de distinto tipo.

12.3. Resultados de la Similitud de Gower

12.3.1. Coherencia interna de los grupos

La Tabla 17 presenta la similitud promedio de Gower calculada entre todos los pares de manantiales que pertenecen al mismo tipo de clasificación química. En los tres casos, los valores superan 0.68, lo que indica que los manantiales de un mismo tipo comparten de forma consistente sus perfiles de olor, categoría de pH y categoría de temperatura.

Tabla 17: Similitud promedio de Gower dentro de cada tipo de agua (pares con igual clasificación química).

Tipo de agua	Similitud promedio	N pares
Bicarbonatada	0.727	4,005
Sulfatada	0.705	1,176
Clorurada	0.680	1,326

La Bicarbonatada presenta la mayor cohesión interna (0.727), resultado coherente con su predominancia en el inventario (46.6 % de los registros, Tabla 1) y con su asociación con rocas sedimentarias carbonatadas que producen condiciones fisicoquímicas homogéneas: pH predominantemente neutro-básico, temperatura tibia y ausencia de olor en la mayoría de los casos.

La Sulfatada alcanza 0.705 a pesar de tener el perfil fisicoquímico más extremo del dataset: alta proporción de pH ácido (73.2 %) y la mayor concentración de olores intensos (Fuerte + H_2S = 26 %). Su cohesión refleja que el proceso de oxidación de sulfuros volcánicos produce condiciones sistémicamente similares entre manantiales de este tipo.

La Clorurada registra la menor cohesión interna (0.680), lo que es esperable dado que este tipo puede originarse tanto en sistemas volcánicos de alta temperatura como sistemas de temperatura promedio, generando mayor heterogeneidad interna en pH y temperatura.

12.3.2. Similaridad entre tipos distintos

La Tabla 18 muestra la similaridad promedio entre pares de manantiales de distinta clasificación química. En los tres casos, los valores están por debajo de 0.46, considerablemente menores que los obtenidos dentro de cada grupo (Tabla 17), lo que confirma que la clasificación química separa efectivamente a los manantiales en grupos fisicoquímicamente distintos.

Tabla 18: Similaridad promedio de Gower entre tipos de agua distintos.

Par de tipos	Similaridad promedio	N pares
Bicarbonatada vs Clorurada	0.453	4,680
Bicarbonatada vs Sulfatada	0.410	4,410
Clorurada vs Sulfatada	0.393	2,548

El par Bicarbonatada–Clorurada es el más similar entre tipos distintos (0.453). Ambos tipos pueden coexistir en sistemas de baja temperatura con influencia de rocas sedimentarias, y comparten con mayor frecuencia categorías de pH neutro y temperatura tibia, lo que reduce su distancia de Gower.

El par Clorurada–Sulfatada es el menos similar (0.393), el valor más bajo del análisis. Esto refleja la diferencia estructural entre sus mecanismos de formación: las aguas Cloruradas tienden a ser neutras con temperatura alta, mientras que las Sulfatadas son predominantemente ácidas con presencia de H_2S , como ya evidenciaron las tablas cruzadas de pH $\times$ clasificación (Tabla 10) y pH $\times$ olor (Tabla 12).

12.3.3. Distribución general de las similaridades

Tabla 19: Resumen estadístico de la distribución de similaridades de Gower sobre todos los pares de manantiales ($n = 18,145$ pares).

Medida	Valor
Mínimo	0.000
Mediana	0.500
Media	0.528
Máximo	1.000

La mediana de 0.500 y la media de 0.528 indican una similaridad moderada en el conjunto global de pares. Es importante señalar que, dado que el análisis emplea cuatro variables categóricas con dos o tres niveles cada una, la similaridad de Gower no toma valores continuos sino un conjunto discreto de valores posibles determinados por las combinaciones de categorías. Por esta razón, la mediana de 0.500 no debe interpretarse como el centro de una distribución continua, sino como el valor más frecuente en pares que comparten exactamente la mitad de sus características.

El rango completo $[0, 1]$ confirma que existen en el dataset tanto pares de manantiales idénticos en las cuatro variables (mismo tipo, mismo perfil de olor, mismo rango de pH y misma categoría de temperatura) como pares completamente distintos en todas ellas, representando los extremos del espectro hidrogeoquímico colombiano.

Los resultados de la similaridad de Gower son consistentes con el conjunto del análisis exploratorio. En particular, la baja similaridad entre Clorurada y Sulfatada (0.393) y la alta cohesión interna de la Bicarbonatada (0.727) son la expresión numérica de los procesos geológicos descritos en la introducción: la predominancia de rocas carbonatadas produce aguas bicarbonatadas homogéneas, mientras que la actividad volcánica genera aguas sulfatadas y cloruradas con perfiles más variables entre sí.

13. Estimación de la distribución de los datos usando funciones de densidad kernel

Además del histograma, una forma ampliamente utilizada para estudiar la distribución de una variable es la estimación de densidad mediante funciones Kernel (Kernel Density Estimation, KDE). Este método proporciona una aproximación continua de la función de densidad de probabilidad a partir de los datos observados, permitiendo visualizar con mayor claridad la forma de la distribución, identificar posibles modas y reducir la dependencia de la elección de intervalos propia de los histogramas.

La calidad de la estimación depende principalmente de dos elementos: el ancho de banda (*bandwidth*), que controla el grado de suavizado de la curva, y la función Kernel utilizada para asignar pesos a las observaciones cercanas. En esta sección se evalúa el efecto de ambos factores sobre la estimación de la distribución de las variables del conjunto de datos.

Para ello, se realizaron los siguientes análisis:

1. Se mantuvo fija la función Kernel y se compararon diferentes valores del ancho de banda para analizar cómo varía el grado de suavizado de la distribución estimada.
2. Se fijó un mismo ancho de banda y se compararon distintas funciones Kernel con el fin de evaluar las diferencias entre las estimaciones obtenidas.
3. En cada caso, se representó simultáneamente el histograma de la variable y la curva de densidad estimada para facilitar la comparación visual entre ambas representaciones.

13.0.1. Efecto del ancho de banda (h)

La Figura 27 muestra la estimación de densidad kernel de la variable CONDUCTIVIDAD (transformada a escala $\log_{10}$), utilizando un kernel Gaussiano fijo y tres anchos de banda distintos: $h_{\text{pequeño}} = 0,04$, $h_{\text{óptimo}} = 0,16$ (regla de Silverman, bw.nrd0) y $h_{\text{grande}} = 0,56$.




Figura 27: Comparación de anchos de banda usando kernel Gaussiano.

Se observa que:

- Con $h_{\text{pequeño}} = 0,04$ la curva presenta múltiples picos y oscilaciones que tienen en cuenta el ruido. Esto corresponde a una estimación con varianza alta y bajo sesgo: la densidad se *sobreajusta* a los datos y pierde capacidad de generalización, dificultando la identificación de la forma real de la distribución.
- Con $h_{\text{óptimo}} = 0,16$ la curva logra un balance adecuado entre suavidad y fidelidad a los datos: conserva la moda principal (alrededor de $\log_{10}(\text{Conductividad}) \approx 3,3$) y las variaciones secundarias visibles en el histograma (una pequeña moda cercana a 4,5), sin generar ruido artificial. Este resultado es consistente con el objetivo del ancho de banda óptimo: minimizar el error cuadrático medio integrado (MISE) entre la densidad estimada y la densidad real.
- Con $h_{\text{grande}} = 0,56$ la curva se sobreesuaviza, generando una estimación con sesgo alto y baja varianza. Se pierde la moda principal (la curva se aplana), entregando una representación demasiado simplificada de la distribución real.

En conclusión, el ancho de banda $h_{\text{óptimo}}$ ofrece la mejor calidad de estimación, al reflejar tanto la tendencia central como las irregularidades relevantes del histograma, evitando los extremos de sobreajuste (h pequeño) y sobreesuavizado (h grande).

13.0.2. Efecto de la función kernel

La Figura 28 presenta la comparación de cuatro funciones kernel (Gaussiano, Epanechnikov, Rectangular y Triangular) manteniendo fijo el ancho de banda óptimo ($h = 0,16$).




Figura 28: Comparación de funciones kernel con ancho de banda fijo.

A diferencia del ancho de banda, la elección de la función kernel tiene un efecto mucho menor sobre la calidad de la estimación:

- Las curvas Gaussiana, Epanechnikov y Triangular son prácticamente indistinguibles entre sí en la mayor parte del dominio, ya que las tres son funciones continuas y suaves que ponderan de forma decreciente las observaciones según su distancia al punto de evaluación.

- El kernel Rectangular produce una curva menos suave que las demás funciones kernel. Esto ocurre porque trata por igual a todas las observaciones cercanas y no considera las que están fuera del ancho de banda, generando pequeñas irregularidades en la estimación de la densidad.

Se puede afirmar entonces que la elección del ancho de banda es mucho más determinante para la calidad de la estimación que la elección de la forma funcional del kernel. Kernels distintos, bajo el mismo h , convergen a estimaciones muy similares, mientras que un h mal elegido puede distorsionar completamente la forma de la densidad estimada, independientemente del kernel utilizado.

14. Conclusiones

El análisis exploratorio del inventario geoquímico de manantiales y fumarolas colombianos permitió caracterizar el estado fisicoquímico de 320 puntos de afloramiento de agua subterránea a lo largo del territorio nacional, evidenciando patrones consistentes con la geología volcánica y tectónica del país [1].

En cuanto a las variables numéricas, se encontró que la mayoría de los manantiales presentan aguas ligeramente ácidas, con una mediana de pH de 6,51, valor más representativo que la media (6,33) debido a la presencia de registros con pH cercano a cero que sesgan la distribución hacia la izquierda (asimetría = $-1,66$). El coeficiente de variación del pH ($CV = 27,0$, %) es el más bajo de las cinco variables analizadas, confirmando que es la más homogénea en términos relativos. La temperatura mediana de 39°C confirma que el dataset está dominado por aguas termales ($CV = 38,3$, %).

Variables como la conductividad eléctrica y el sodio presentaron las distribuciones más asimétricas del análisis (asimetría de 13,19 y 5,29 respectivamente) y los coeficientes de variación más altos ($CV = 391,2$ % y $CV = 309,4$ %), confirmando que sus medias aritméticas carecen de valor descriptivo. En estos casos, la mediana y la MEDA resultaron ser los únicos estimadores confiables de tendencia central y dispersión. El calcio presentó un comportamiento intermedio ($CV = 118,6$ %), coherente con su asimetría más moderada y la presencia generalizada de rocas carbonatadas en el subsuelo colombiano.

Respecto a las variables categóricas, el agua de tipo Bicarbonatada representa el 46,6 % del total de registros, lo que refleja la predominancia de rocas sedimentarias carbonatadas en el subsuelo colombiano. El 69,8 % de los manantiales no presenta olor detectable; sin embargo, el análisis cruzado mostró que los manantiales con olor Fuerte y a H_2S presentan mayor proporción de agua ácida (70,6 % y 60,0 % respectivamente) que los inodoros (52,7 %). La tabla cruzada pH $\times$ clasificación reveló que la Sulfatada es el tipo de agua más ácido (71,9 % de sus manantiales son ácidos), confirmando su asociación con la oxidación de sulfuros de origen volcánico.

El gráfico de dispersión entre temperatura y pH reveló una tendencia negativa leve: los manantiales más calientes tienden a ser más ácidos, coherente con el aporte de gases ácidos (CO_2 , H_2S) provenientes de fluidos magmáticos profundos. La correlación positiva entre sodio y conductividad confirmó que el sodio es el principal ion responsable de la mineralización eléctrica del agua en estos sistemas.

La transformación logarítmica es necesaria, pero no suficiente, para revelar la verdadera forma de la distribución. Si bien trabajar en escala $\log_{10}$ comprime el rango extremo de la conductividad (0 a $278\,000\ \mu\text{S}/\text{cm}$) y permite visualizar mejor el histograma, solo mediante la estimación kernel con un ancho de banda adecuadamente calibrado ($h_{\text{óptimo}} = 0,16$, regla de Silverman) fue posible distinguir la moda principal de una posible submoda secundaria —evidencia de al menos dos poblaciones de manantiales con procesos de mineralización distintos— sin caer en el sobreajuste (h pequeño) ni en el sobresuavizado que oculta esta estructura (h grande).

El ancho de banda domina sobre la elección del kernel. Consistente con la teoría clásica de estimación no paramétrica (Silverman, 1986), la comparación entre kernels Gaussiano, Epanechnikov, Rectangular y Triangular bajo el mismo h mostró diferencias mínimas —salvo la rugosidad esperable del kernel Rectangular—. Esto tiene una implicación práctica directa para el proyecto: el esfuerzo de calibración en futuros análisis debe concentrarse en la selección del ancho de banda (o en el uso de selectores automáticos como validación cruzada), y no en debatir qué función kernel usar.

Finalmente, el análisis de datos crudos evidenció la necesidad de una etapa de limpieza rigurosa: se identificaron valores de pH iguales a 0,0, temperaturas de 0 °C y concentraciones negativas de algunos iones, todos ellos errores de registro que deberán ser tratados antes de cualquier modelo predictivo. Este trabajo sienta las bases para una etapa posterior de imputación, normalización y modelado que permita estimar el comportamiento de los manantiales en horizontes de 5 a 10 años, contribuyendo a la gestión sostenible de los recursos hídricos y geotérmicos de Colombia.

Referencias

- [1] Santiago Fernández Fernández, José María Cordero Sánchez, Alejandro Córdoba, and Alejandro Córdoba Largo. *Estadística descriptiva*. Esic Editorial, 2002.
- [2] Werner F. Giggenbach. Chemical techniques in geothermal exploration. *Applications of Geochemistry in Geothermal Reservoir Development*, 1991.
- [3] U.S. Geological Survey. Mining and water quality, June 2018. Water Science School. Accessed: 2026-07-22.
- [4] Claudia Alfaro Valero and Alcides Aguirre Corrales. Geoquímica de fuentes minerales y termales del complejo volcánico cerro bravo–cerro machín, colombia. *Boletín Geológico*, (41):76–120, 2006.