




Medición e identificación de variables para la estadística descriptiva y exploratoria de manantiales

Vargas Gómez, Santiago¹; Vargas Gómez, Cristian²

Departamento de Estadística, Universidad Nacional de Colombia

30 de abril de 2026

Resumen: Este artículo se enfocará en el análisis de un conjunto de datos numéricos y no numéricos que brindan información sobre la localización, características del punto de emergencia (o sitios de prevención) y composición química de los manantiales existentes en la región de Colombia, contribuyendo así a localizar y caracterizar los yacimientos geotérmicos existentes a lo largo del extenso territorio del país. Los datos fueron obtenidos del Portal de Datos Abiertos del servicio geológico colombiano.

Palabras clave: Manantiales, Fumarolas, Dataset, Estadística, Elementos.

1. Introducción

El estudio de las fuentes termales y manantiales en Colombia constituye una ventana directa hacia la complejidad de los sistemas hidrogeológicos y geotérmicos del país. Debido a su ubicación en una zona de convergencia tectónica y actividad volcánica significativa, el subsuelo colombiano alberga fluidos que han interactuado con diversas litologías en condiciones de alta presión y temperatura. El presente trabajo analiza el inventario geoquímico de puntos de agua subterránea, una base de datos fundamental para la gestión e identificación de recursos hídricos, junto con la exploración de energías renovables.

A través de la caracterización de variables que van desde los parámetros fisicoquímicos básicos hasta la presencia de elementos traza como el Litio, el Cesio y el Antimonio, así como el análisis de isótopos estables como el Deuterio, es posible rastrear el ciclo del agua desde su recarga en las altas cumbres hasta su descarga en los manantiales. Estos componentes no solo funcionan como indicadores de la calidad del agua y su aptitud para el consumo humano, sino que actúan como "trazadores químicos" que revelan la profundidad de los reservorios, el tiempo de residencia en la roca y la influencia de fluidos magmáticos o fallas geológicas activas.

A través de este análisis, se busca describir la composición química de los manantiales, comprendiendo

la metodología detrás de las mediciones realizadas y la relevancia de cada una de las variables en la interpretación de los procesos geológicos que moldean nuestro territorio. Comprender la importancia y la influencia de las variables en el conjunto de datos es útil para saber la influencia que cada una de ellas tiene en la estimación de situaciones que dependen del tiempo, ayudando a comprender de que manera se comportará el manantial en los próximos 5 o incluso 10 años.

2. Objetivos del Análisis Exploratorio de Datos

2.1. Describir la distribución de las variables fisicoquímicas principales

Se busca caracterizar la distribución de las variables fisicoquímicas más representativas del estado del manantial: pH, temperatura y conductividad. Estas variables fueron seleccionadas debido a su relevancia en la evaluación de la calidad del agua y a la amplitud de sus rangos de valores.

Para este propósito, se emplean histogramas y funciones de distribución acumulada empírica (ECDF), los cuales permiten observar la forma de la distribución, la presencia de valores atípicos y la dispersión de los datos. En particular, la conductividad presenta un rango amplio (de 0 a 278,000 $\mu\text{S}/\text{cm}$), lo que

evidencia variabilidad significativa incluso antes del proceso de limpieza de datos.

2.2. Identificar el tipo de agua dominante en Colombia

El objetivo es determinar cuál es el tipo de agua predominante en el conjunto de datos. Para ello, se analizan las variables categóricas *CLASIFICACIÓN* y *OLOR*, ya que son las únicas que presentan un significado geoquímico relevante.

Se utilizan gráficos de barras y diagramas de pastel (pie chart), que permiten visualizar la frecuencia relativa de cada categoría y facilitar la identificación de las clases dominantes.

2.3. Comparar el olor del agua según su tipo

Se pretende analizar la relación entre el tipo de agua y su olor, utilizando conjuntamente las variables categóricas *CLASIFICACIÓN* y *OLOR*.

Para este análisis se emplean gráficos de barras comparativas, los cuales permiten observar cómo se distribuyen los diferentes olores dentro de cada tipo de agua. Esta relación es particularmente relevante desde el punto de vista geoquímico, ya que ciertos tipos de agua, como las sulfatadas, suelen asociarse con ambientes volcánicos que generan sulfuro de hidrógeno (H_2S), responsable del característico olor a huevo.

2.4. Explorar relaciones entre variables numéricas

El objetivo es identificar posibles relaciones entre variables numéricas del conjunto de datos. A diferencia de los histogramas, que analizan variables individuales, en este caso se busca evaluar cómo dos variables se comportan de manera conjunta.

Se utilizan gráficos de dispersión para analizar las relaciones entre temperatura y pH, así como entre sodio y conductividad. Estos gráficos permiten detectar patrones, tendencias o correlaciones entre las variables, lo que puede aportar información relevante sobre los procesos fisicoquímicos del sistema.

2.5. Identificar el estado del dataset antes de la limpieza

Se busca evaluar la calidad y completitud del conjunto de datos previo a su procesamiento. Este análisis es fundamental para justificar la necesidad de aplicar técnicas de limpieza.

Para ello, se utilizan gráficos de barras que muestran la cantidad de mediciones por año, así como mapas de datos faltantes que permiten identificar patrones de ausencia de información. Estos elementos proporcionan una visión clara del estado inicial del dataset y respaldan las decisiones metodológicas tomadas en etapas posteriores del análisis.

3. Identificación y clasificación de datos

1. **ID_MANANTIAL:** Este dato numérico es un código único para la identificación del afloramiento de agua.
2. **LATITUD/LONGITUD:** Estos datos numéricos se refieren a las coordenadas geográficas tomadas en grados decimales con el fin de acoplarse al estándar del GPS.
3. **FECHA:** Dato numérico que indica el día y hora en que se realizó la medición o toma de muestra.
4. **CAUDAL:** Este dato numérico decimal expresa la cantidad de volumen de agua que pasa por el área determinada de cada manantial, es posible que el cálculo se haya realizado a partir de la siguiente fórmula

$$Q = \frac{V}{t} \quad (1)$$

en donde V expresa el volumen y t el tiempo.

5. **TEMPERATURA:** Dato numérico decimal que expresa la temperatura del agua en su punto de salida útil para clasificar si es agua fría o termal)
6. **OLOR:** Dato alfabético que describe sensorialmente el olor del agua.
7. **CARBONATO_/BICARBONAT:** Dato numérico decimal que tiene la cantidad en miliequivalentes por litro (mEq/l) de carbonatos y bicarbonatos; útil para la determinación del pH.
8. **SULFURO_HI:** Dato numérico decimal que indica la cantidad de ácido sulfúrico (H_2SO_4), este ácido es determinante para la reducción del pH del agua.
9. **PH LABORATORIO:** Medición final del pH de las muestras de agua tomadas.

10. **CONDUCTIVIDAD:** Dato numérico que indica la capacidad del agua para conducir electricidad; indica la cantidad total de sales disueltas y está dado en microsiemens por centímetro:

$$\frac{\mu S}{cm} \quad (2)$$

11. **ALCALINIDAD:** Dato numérico decimal que expresa la capacidad del agua para neutralizar ácidos; se expresa principalmente en miligramos por litro de carbonato de calcio:

$$\frac{mg}{L} \quad CaCO_3 \quad (3)$$

12. **SOLIDOS:** Dato numérico decimal que representa la cantidad de material orgánico e inorgánico disuelto o suspendido presente en un volumen de agua; se expresa en miligramos por litro o partes por millón (*ppm*):

$$\frac{mg}{L} \quad (4)$$

13. **CLORUROS:** Dato numérico decimal que representa la masa de iones de cloro que provienen de disolución de minerales en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (5)$$

14. **SULFATOS:** Dato numérico decimal que representa la masa de sales ácido sulfúrico que provienen de erosión de minerales en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (6)$$

15. **NITRATOS:** Dato numérico decimal que representa la masa de nitratos que provienen de contaminación por uso de fertilizantes agrícolas en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (7)$$

16. **CALCIO:** Dato numérico decimal que representa la dureza del agua y la disolución de rocas calizas o dolomías.

17. **MAGNESIO:** Dato numérico decimal que representa la masa de magnesio que proviene de la erosión en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (8)$$

18. **ESTRONCIO:** Dato numérico decimal que representa la masa de estroncio que proviene de la erosión natural en un volumen de agua; se expresa en microgramos por litro :

$$\frac{\mu g}{L} \quad (9)$$

19. **SODIO:** Dato numérico decimal que representa la masa de sales de sodio que proviene de la erosión en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (10)$$

20. **POTASIO:** Dato numérico decimal que representa la masa de potasio que proviene de la interacción del agua con las rocas en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (11)$$

21. **HIERRO:** Dato numérico decimal que representa la masa de hierro que proviene de la disolución natural de minerales en el subsuelo en un volumen de agua; se expresa en microgramos por litro :

$$\frac{\mu g}{L} \quad (12)$$

22. **MANGANESO:** Dato numérico decimal que representa la cantidad de manganeso presente en cada manantial bajo el estándar de miligramos por litro; útil para indicar si el agua ha estado en un ambiente anóxico (sin oxígeno):

$$\frac{mg}{L} \quad (13)$$

$$\frac{mg}{L} \quad (14)$$

23. **ALUMINIO:** Dato numérico decimal que representa la masa de aluminio que proviene de disolución natural en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (15)$$

24. **SILICIO:** Dato numérico decimal que representa la masa de silicio en un volumen de agua; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (16)$$

25. **SILICE:** Dato numérico decimal que representa la cantidad de silice que hay en cada manantial, es importante en geotermia para calcular la temperatura de lo que podemos denominar un .estanque”profundo; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (17)$$

26. **BORO:** Dato numérico decimal que representa la masa de boro en un volumen de agua, su análisis se realiza para conocer su conveniencia para consumo humano; se expresa en microgramos por litro :

$$\frac{\mu g}{L} \quad (18)$$

27. **LITIO:** Dato numérico decimal que representa la cantidad de litio que hay en cada manantial, indica que el agua ha tenido un largo tiempo de residencia en el subsuelo o que ha circulado a grandes profundidades, lo que da lugar a posibles interacciones con rocas ígneas lo cual es clave para identificar sistemas geotérmicos o aportes de aguas profundas. Se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (19)$$

28. **FLUOR:** Dato numérico decimal que representa la masa de fluoruro de calcio en un volumen de agua, proviene de la meteorización de rocas ricas en minerales; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (20)$$

29. **MERCURIO:** Dato numérico decimal que representa la masa de mercurio en un volumen de agua, proviene principalmente por la contaminación debido a la minería ilegal; se expresa en microgramos por litro :

$$\frac{\mu g}{L} \quad (21)$$

30. **ZINC:** Dato numérico decimal que representa la cantidad de zinc en un volumen de agua, sirve como un indicador de la interacción que existe entre el agua y la roca con depósitos de sulfuros; es una herramienta clave para la prospección geoquímica. Las anomalías en su concentración pueden revelar la presencia de mineralizaciones metálicas ocultas en el subsuelo o alertar sobre

procesos de contaminación por actividades industriales y mineras que afecten la calidad del recurso hídrico.

$$\frac{\mu g}{L} \quad (22)$$

31. **YODURO:** Dato numérico decimal que representa la masa de iones de yodo en un volumen de agua, proviene de la erosión natural y su concentración es más escasa en zonas montañosas; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (23)$$

32. **BROMURO:** Dato numérico decimal que representa la masa de bromuro en un volumen de agua, se presenta mayormente en zonas con depósitos salinos o influencia marina; se expresa en miligramos por litro :

$$\frac{mg}{L} \quad (24)$$

33. **NIQUEL:** Dato numérico decimal que representa la masa de niquel presente en un volumen de agua, su presencia es útil para la exploración geológica puesto que suele estar asociado a la degradación parcial o total de las rocas y los minerales, se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (25)$$

34. **ARSENICO:** Dato numérico decimal que identifica la cantidad de arsenico presente en el agua de los manantiales. Este elemento se encuentra en trazas muy pequeñas pero significativas debido a que permite identificar si el agua de un manantial es apta para el consumo humano. Debido a que se encuentra en pequeñas cantidades, se suele medir en microgramos por litro

$$\frac{\mu g}{L} \quad (26)$$

35. **ANTIMONIO:** Dato numérico decimal que representa la masa de antimonio en un volumen de agua, proviene tanto de forma natural por la meteorización de minerales de sulfuro como contaminación por minería; se expresa en microgramos por litro :

$$\frac{\mu g}{L} \quad (27)$$

36. **CESIO:** Dato numérico decimal que representa la masa de cesio presente en un volumen de agua, el cesio es fundamental como un indicador de sistemas geotérmicos de alta temperatura, debido a que se libera de las rocas cuando el agua subterránea alcanza temperaturas muy altas, se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (28)$$

37. **RUBIDIO:** Dato numérico decimal que representa la masa de rubidio presente en un volumen de agua, debido a que tiene una gran similitud química con el potasio, la relación entre el rubidio y otros elementos permite determinar la estabilidad de los fluidos térmicos y confirmar si el agua ha circulado por niveles profundos de la corteza terrestre, se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (29)$$

38. **DEUTERIO:** Dato numérico decimal que representa la masa de deuterio presente en un volumen de agua, sirve como una para determinar el origen y la altitud de recarga del agua, se mide en ppm (partes por millón).

39. **OXIGENO18:** Dato numérico decimal que representa la masa del isótopo de oxígeno en un volumen de agua, se utiliza para identificar fuentes de agua, identificar la mezcla, altitud y temperatura de precipitación; se expresa en partes por millón (ppm)

40. **GAS CARBON:** Dato numérico decimal que representa la masa de CO₂ presente en un volumen de agua, su presencia indica el grado de interacción con fuentes profundas y se mide en miligramos por litro.

$$\frac{mg}{L} \quad (30)$$

41. **SULFURO.1:** Dato numérico decimal que representa la masa de ácido sulfhídrico presente en un volumen de agua, su presencia indica condiciones de reducción total (ausencia de oxígeno) y suele estar vinculado a dos orígenes principales y se mide en miligramos por litro:

$$\frac{mg}{L} \quad (31)$$

42. **METANO:** Dato numérico decimal que representa la masa de metano presente en un volumen de agua, su monitoreo es clave para la seguridad, ya que el metano es un gas inflamable, y en la exploración de recursos puede dar pistas sobre la proximidad de yacimientos de gas natural. Se mide en miligramos por litro:

$$\frac{mg}{L} \quad (32)$$

43. **ARGÓN:** Dato numérico decimal que representa la masa de argón presente en un volumen de agua, el argón indica la influencia de la atmósfera en el sistema subterráneo y se mide en miligramos por litro:

$$\frac{mg}{L} \quad (33)$$

44. **NITRÓGENO:** Dato numérico decimal que representa la masa de nitrógeno presente en un volumen de agua, el nitrógeno gaseoso sirve para verificar si hubo contacto excesivo con el aire durante la toma de la muestra o si existen procesos de desnitrificación biológica en el subsuelo. Se mide miligramos por litro:

$$\frac{mg}{L} \quad (34)$$

45. **HELIO:** Dato numérico decimal que representa la masa de helio presente en un volumen de agua, su presencia es una señal clara de que existen fracturas profundas que conectan el manantial con rocas muy antiguas o con actividad magmática, funcionando como un "mensajero" de lo que ocurre a kilómetros de profundidad. Se mide en centímetros cúbicos por kilogramo:

$$\frac{cm^3}{kg} \quad (35)$$

46. **HIDRÓGENO:** Dato numérico decimal que representa la masa del hidrógeno en un volumen de agua, proviene del subsuelo mediante reacciones geoquímicas y se encuentra disuelto como gas natural; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (36)$$

47. **RADÓN:** Dato numérico decimal que representa la masa de radón en un volumen de agua, proviene de la erosión del uranio, torio y radio en suelos

subterráneos, se encuentra en niveles más altos en áreas con granito o uranio en el subsuelo, disolviéndose fácilmente en aguas subterráneas; se expresa en becquerelios por litro

$$\frac{Bq}{L} \quad (37)$$

48. **PH_INSITU**: Medición inicial del pH en el sitio de la toma de muestras.

49. **AMONIO**: Dato numérico decimal que representa la masa de amonio en un volumen de agua, proviene de descomposición natural de los suelos con materia orgánica y hierro, su disposición en manantiales puede indicar contaminación por residuos fecales; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (38)$$

50. **OXIGENO**: Dato numérico decimal que representa la masa de oxígeno disuelto en un volumen de agua, proviene del agua del subsuelo y suele ser escaso una vez sale del manantial; se expresa en miligramos por litro:

$$\frac{mg}{L} \quad (39)$$

51. **OBSERVACIO**: Dato alfabético que señala comentarios o apreciaciones adicionales sobre la ubicación, estado, y demás temas de interés.

52. **DEPOSITO_**: Dato alfabético que indica sobre que tipo de depósitos se encuentra ubicado el manantial.

53. **CLASIFICACIÓN**: Dato alfabético que muestra la clasificación del manantial dependiendo de sus cationes y aniones predominantes.

54. **MONOXIDO_C**: Dato numérico decimal que representa la cantidad de monóxido de carbono disuelto en un volumen de agua, proviene de la degradación de carbono orgánico y se encuentra con mayor frecuencia en zonas volcánicas; se mide en microgramos por litro:

$$\frac{\mu g}{L} \quad (40)$$

55. **FOSFATOS**: Dato numérico decimal que representa la cantidad de ortofosfatos, polifosfatos y

fosfatos orgánicos disueltos en un volumen de agua, provienen de la erosión de suelos y rocas, y de la descomposición de material orgánico; se mide en miligramos por litro:

$$\frac{mg}{L} \quad (41)$$

4. Análisis de variables, categorización y limpieza de datos

En esta sección se expondrán los problemas encontrados en el dataset relacionados con datos faltantes o incompletos; se planteará una solución de estandarización de errores y valores faltantes para que no generen ruido en el momento de utilizar los datos para estimaciones y posibles predicciones. Es importante generar una categorización de las variables para que sean más fáciles de analizar y utilizar. El conjunto de datos engloba variables que son elementos químicos, por lo que resulta pertinente clasificarlos según la incidencia que tienen en los procesos fisicoquímicos que afectan las características de cada uno de los manantiales identificados.

5. Variables removidas

5.1. A. Variables con Varianza Cero (10 variables eliminadas)

1. GAS_CARBON

- **Razón**: Todos los valores = 0
- **Significado**: No se midió gas carbónico en ninguna muestra.
- **Impacto**: Sin variabilidad y por ende, sin información predictiva.

2. SULFURO_1

- **Razón**: Todos los valores = 0
- **Nota adicional**: Es un duplicado de SULFURO_HI (que sí tiene variabilidad). Esta variable probablemente fue un error de registro duplicado.

3. METANO

- **Razón**: Todos los valores = 0
- **Contexto**: El metano es un gas que puede indicar actividad orgánica o volcánica.

4. ARGON

- **Razón:** Todos los valores = 0
- **Significado:** Gas noble que no se midió o no se detectó.

5. NITROGENO

- **Razón:** Todos los valores = 0
- **Contexto:** Gas disuelto que podría indicar contacto con atmósfera.

6. HELIO

- **Razón:** Todos los valores = 0
- **Contexto:** Gas noble usado en estudios de origen de agua (profundo vs superficial).

7. HIDROGENO

- **Razón:** Todos los valores = 0
- **Contexto:** Gas que puede indicar procesos redox o actividad geotérmica.

8. RADON

- **Razón:** Todos los valores = 0
- **Contexto:** Gas radiactivo importante para salud pública, pero no fue medido.

9. OXIGENO

- **Razón:** Todos los valores = 0
- **Nota:** Diferente de OXIGENO18 (isótopo) que SÍ se conservó.

10. MONOXIDO_C

- **Razón:** Todos los valores = 0
- **Significado:** Monóxido de carbono, no detectado.

5.2. B. Variables Duplicadas (5 variables eliminadas, se conservó 1 de cada par)

Estas variables representan las mismas mediciones pero en diferentes formatos, unidades o momentos. Se conservó la versión con más datos válidos o más confiables.

11. BICARBON_1 (Eliminada, se conservó BICARBONAT)

- **Análisis:** Ambas tienen 320 valores válidos (sin diferencia).

- **Decisión:** Se conservó BICARBONAT porque es el nombre más estándar.
- **Impacto:** Ninguno, son idénticas.

12. CARBONATOS (Eliminada, se conservó CARBONATO_)

- **Análisis:** Ambas tienen 320 valores válidos.
- **Decisión:** Se conservó CARBONATO_.
- **Impacto:** Ninguno, datos idénticos.

13. PH_IN_SITU (Eliminada, se conservó PH_LABORATORIO)

- **Razón:** Representa pH medido en campo vs laboratorio.
- **Análisis:** Es mejor conservar la medida de pH en laboratorio, pues suele ser más precisa gracias al uso de equipos calibrados.
- **Decisión:** Conservar PH_LABORATORIO.

14. CONDUCTIVIDAD ELÉCTRICA (Eliminada, se conservó CONDUCTIVIDAD)

- **Razón:** Mismo parámetro, probablemente diferente método o instrumento.
- **Decisión:** Se conservó CONDUCTIVIDAD.

15. SILICE (Eliminada, se conservó SILICIO)

- **Contexto químico:** Sílice es el compuesto (SiO_2) y Silicio el elemento (Si). En análisis de agua, miden lo mismo con un factor de conversión.
- **Decisión:** Se conservó SILICIO (representa el elemento, más fundamental).

6. Metodología

El análisis exploratorio se realizó en el entorno de programación estadística R, utilizando principalmente las librerías ggplot2 para la visualización, dplyr y stringr para la manipulación de datos, y moments para el cálculo de asimetría y curtosis. El flujo de trabajo se dividió en dos archivos: funciones.r, que define las funciones personalizadas reutilizables (moda, sd_pobl, meda y normalizar), y Script.r, que ejecuta el análisis sobre el conjunto de datos.

6.1. Selección de variables

De las 64 columnas originales del dataset, se descartaron las variables con varianza cero (todos los valores iguales a cero, sin información) y las variables duplicadas, según lo establecido en la Sección 4. Para el análisis exploratorio se conservaron:

- **5 variables numéricas:** PH.LABORATORIO, TEMPERATUR, CONDUCTIVIDAD, CALCIO, SODIO. Estas variables representan los parámetros físico-químicos más relevantes para caracterizar un manantial y son las que tienen mayor cobertura de datos en el dataset.
- **3 variables no numéricas:** CLASIFICACIÓN, OLOR, y FECHA. De esta última se extrajo el año (ANIO) como variable temporal categórica.

6.2. Medidas estadísticas utilizadas

Para cada variable numérica se calcularon las siguientes medidas, seleccionadas en función de las características observadas en los datos crudos:

- **Media y mediana:** medidas de tendencia central básicas. Se calcularon ambas porque su comparación directa permite detectar asimetría sin necesidad de graficar. Las ecuaciones se presentan a continuación de manera respectiva.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ es impar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{si } n \text{ es par} \end{cases}$$

- **Media recortada al 5 %:** se aplicó en todas las variables numéricas porque el dataset contiene valores atípicos extremos (por ejemplo, conductividad de hasta 278,000 $\mu\text{S}/\text{cm}$ o sodio de hasta 16,926 mg/L). La media recortada elimina el 5 % de los valores más altos y más bajos antes de promediar, produciendo un estimador más representativo del comportamiento típico. En R se obtiene con `mean(x, trim = 0.05)`.
- **Moda:** valor más frecuente. R no incluye esta función de forma nativa, por lo que se definió en funciones.r. Se calculó en todas las variables para cumplir con los requerimientos del análisis.

$$\text{Moda} = \arg \max f(x)$$

- **Desviación estándar muestral y poblacional:** la muestral (`sd()` en R) divide entre $n - 1$ y se usa cuando los datos son una muestra de una población mayor; la poblacional divide entre N y se usa cuando los datos representan la población completa. Dado que el dataset es un inventario parcial del país, ambas versiones se reportan. Las desviaciones estándar muestral y poblacional se calculan respectivamente:

$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n - 1}}$$

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{\mu})^2}{N}}$$

- **MEDA (Mediana de Desviaciones Absolutas):** se definió como:

$$\text{MEDA} = \text{mediana}(|x_i - \text{mediana}(x)|)$$

Se utilizó como alternativa robusta a la desviación estándar en variables con asimetría extrema (conductividad, sodio), donde la desviación estándar clásica queda completamente distorsionada por los valores atípicos.

- **Coefficiente de asimetría (skewness):** calculado con `skewness()` de la librería `moments`. Un valor positivo indica cola hacia la derecha (pocos valores muy altos); negativo indica cola hacia la izquierda. Se utilizó para cuantificar formalmente lo que los histogramas muestran visualmente, su fórmula es la siguiente:

$$\text{asimetria} = \frac{m_3}{S^3}$$

Donde

$$m_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^3$$

- **Curtosis:** calculada con `kurtosis()` de `moments`. Mide qué tan pronunciado es el pico de la distribución y qué tan pesadas son sus colas en comparación con una distribución normal ($\kappa = 3$). Valores $\kappa > 3$ indican colas pesadas y presencia de valores extremos frecuentes. Se calcula de la siguiente manera.

$$\text{curtosis} = \frac{\sum_{i=1}^n (x_i - \bar{X})^4}{nS^4} - 3$$

- **Rango:** diferencia entre el valor máximo y mínimo. Se calculó para detectar valores sospechosos, como el mínimo de 0.0 en PH.LABORATORIO o el de 0°C en TEMPERATUR.

6.3. Visualizaciones

La selección del tipo de gráfico se basó en la naturaleza de las variables involucradas:

- **Histograma** (`geom_histogram`): se aplicó a variables numéricas continuas (PH.LABORATORIO, TEMPERATUR, CONDUCTIVIDAD) para visualizar cómo se distribuyen los valores. El número de intervalos se determinó con la regla de Sturges: $k = 1 + \log_2(n) \approx 1 + \log_2(320) \approx 9$. Para CONDUCTIVIDAD se aplicó escala logarítmica en el eje x (`scale_x_log10()`) debido a que su rango abarca casi seis órdenes de magnitud (0 a 278,000 $\mu\text{S}/\text{cm}$); sin esta transformación, el 95 % de los datos quedaría comprimido en el extremo izquierdo del gráfico y resultaría invisible.
- **Distribución acumulada empírica (ECDF)** (`stat_ecdf`): se aplicó a PH.LABORATORIO y TEMPERATUR. A diferencia del histograma, el ECDF permite hacer afirmaciones cuantitativas directas del tipo “el X % de los manantiales tiene pH menor a 7”. Se trazó una línea vertical en $\text{pH} = 7$ y en $T = 50^\circ\text{C}$ para facilitar la lectura de los umbrales de acidez y temperatura termal respectivamente.
- **Diagrama de barras simple** (`geom_bar`): se aplicó a las variables categóricas CLASIFICACION_LIMPIA, OLOR_LIMPIO y ANIO. `geom_bar` cuenta automáticamente las ocurrencias de cada categoría, por lo que no requiere preprocesamiento. Se orientó horizontalmente (`coord_flip()`) para facilitar la lectura de las etiquetas largas de CLASIFICACION_LIMPIA.
- **Diagrama de barras apilado proporcional** (`geom_bar(position = ‘fill’)`): se utilizó para comparar CLASIFICACION_LIMPIA vs. OLOR_LIMPIO. Con `position = ‘fill’`, cada barra representa el 100 % de los manantiales de ese tipo, lo que permite comparar proporciones entre grupos de tamaños distintos. Esto es más informativo que `position = ‘dodge’` cuando las frecuencias de cada tipo de agua son muy diferentes.

- **Gráfico de torta** (`pie()`): se aplicó a OLOR_LIMPIO y CLASIFICACION_LIMPIA para mostrar la participación porcentual de cada categoría en el total. Se usó la función base de R (`pie()`) en lugar de `ggplot2` por simplicidad, dado que las variables ya tenían pocos niveles después de la normalización.

- **Gráfico de dispersión** (`geom_point + geom_smooth`): se aplicó para explorar relaciones entre pares de variables numéricas: temperatura vs. pH, y sodio vs. conductividad. Este tipo de gráfico es el único adecuado para detectar visualmente si dos variables numéricas se mueven juntas. La línea de tendencia lineal (`method = ‘lm’`) permite ver la dirección de la relación. Para sodio vs. conductividad se aplicó escala logarítmica en ambos ejes por la misma razón que en el histograma de conductividad.

7. Resultados y discusión

7.1. pH de laboratorio

El pH es la variable más directa para caracterizar químicamente el agua de un manantial. Los resultados muestran una media de 6.33 y una mediana de 6.51, lo que indica que la mayoría de los manantiales colombianos presentan aguas ligeramente ácidas. La media recortada al 5 % asciende a 6.46, valor más cercano a la mediana, lo que confirma que un pequeño grupo de manantiales con pH muy bajo (cerca de 0.0) distorsiona la media hacia abajo. El coeficiente de asimetría negativo ($\text{skewness} = -1.66$) cuantifica esta desviación: la distribución tiene una cola hacia la izquierda. La curtosis de 6.62 indica que la distribución es leptocúrtica, con más datos concentrados alrededor del centro que en una distribución normal. El rango de 9.80 (de 0.0 a 9.8) revela la presencia de valores mínimos sospechosos que deberán revisarse en la etapa de limpieza.

El histograma confirma que la mayoría de los registros se concentran entre pH 5 y 8, con un pico alrededor de la neutralidad (pH 7). El diagrama de distribución acumulada (Fig. ??) permite afirmar que aproximadamente el 60 % de los manantiales presenta pH menor a 7, es decir, son ácidos, lo cual es consistente con la presencia generalizada de CO_2 disuelto de origen volcánico en el subsuelo colombiano.

7.2. Temperatura del agua

La temperatura media de 41.75°C y la mediana de 39°C confirman que la mayoría de los puntos de muestreo corresponden a aguas termales. La media recortada (40.99°C) es ligeramente menor que la media completa, lo que indica que los manantiales con temperaturas superiores a 80°C inflan levemente el promedio. El coeficiente de asimetría positivo (skewness = 0,687) refleja esta cola hacia la derecha. La curtosis de 4.003, indica una distribución leptocúrtica, porque existen colas relativamente pesadas, sugiriendo la existencia de algunos valores extremos, particularmente en el rango superior.

La desviación estándar dio como resultado 15.97, que es considerablemente mayor que la desviación absoluta mediana 9, lo que sugiere la presencia de valores extremos que incrementan la dispersión medida respecto a la media. En contraste, la MEDA refleja una menor variabilidad en el grupo central de los datos, indicando que la mayoría de las observaciones se encuentran relativamente concentradas.

7.3. Conductividad eléctrica

La conductividad es la variable con mayor asimetría del análisis. La media de 4,375.75 $\mu\text{S}/\text{cm}$ contrasta fuertemente con la mediana de 1,353.5 $\mu\text{S}/\text{cm}$, y la media recortada al 5 % cae a 2199.234 $\mu\text{S}/\text{cm}$, lo que demuestra que apenas el 5 % de los valores más extremos es responsable de casi la mitad del valor de la media. El coeficiente de asimetría de 13.19 y la curtosis de 206.3 son excepcionales: reflejan que unos pocos manantiales, probablemente fumarolas o puntos con influencia marina directa, presentan conductividades de hasta 278,000 $\mu\text{S}/\text{cm}$. En este contexto, la desviación estándar de 17,116 $\mu\text{S}/\text{cm}$ carece de valor descriptivo y la MEDA de 1141.5 $\mu\text{S}/\text{cm}$ es la única medida de dispersión confiable en cuanto al eje central de los datos.

El histograma se construyó con escala logarítmica en el eje x precisamente por este motivo: en escala lineal, el 95 % de los datos quedaría aplastado en el primer intervalo y los valores extremos dominarían visualmente el gráfico sin aportar información sobre la distribución típica.

7.4. Sodio

El sodio presenta un comportamiento similar a la conductividad, lo cual es esperable dado que es el principal catión en aguas profundas y salinas. La me-

dia de 706.78 mg/L es más del cuatro veces la mediana de 170.8 mg/L. Al recortar el 5 % de los extremos, la media cae a 293.59 mg/L, reduciendo la brecha con la mediana pero sin eliminarla, lo que indica que la asimetría no se debe solo a unos pocos valores extremos sino a una distribución inherentemente sesgada. El coeficiente de asimetría de 5.29 y la curtosis de 31.68 confirman esta estructura. La MEDA de 139.07 mg/L es nuevamente más representativa que la desviación estándar de 2,187 mg/L.

El gráfico de dispersión sodio vs. conductividad, construido con escala logarítmica en ambos ejes, muestra una correlación positiva muy marcada: a mayor concentración de sodio, mayor conductividad. Esto confirma que el sodio es el principal responsable de la mineralización eléctrica del agua en estos manantiales.

7.5. Calcio

El calcio muestra una asimetría moderada comparada con el sodio y la conductividad: la media (98.4 mg/L) es mayor a la mediana (57.4 mg/L), y la media recortada (84.78 mg/L) reduce esta brecha. El coeficiente de asimetría de 2.51 y la curtosis de 12.87 indican una cola derecha presente pero menos extrema. La MEDA de 44.124 mg/L describe que el 50 % central de los manantiales varía en ± 40 mg/L alrededor de la mediana. Este comportamiento es consistente con la geología colombiana: la presencia generalizada de rocas carbonatadas produce concentraciones moderadas de calcio en la mayoría de los manantiales.

7.6. Relación entre temperatura y pH

El gráfico de dispersión temperatura vs. pH, con línea de tendencia lineal, muestra una relación negativa leve: los manantiales más calientes tienden a tener pH más bajo. Esto es consistente con la hipótesis geotérmica: a mayor temperatura, mayor influencia de fluidos magmáticos que aportan gases ácidos (CO_2 , H_2S) y reducen el pH del agua. Sin embargo, la dispersión de los puntos es considerable, lo que indica que la temperatura por sí sola no determina el pH; otros factores como la litología local y el tiempo de residencia del agua en el subsuelo también influyen.

7.7. Variables categóricas

7.7.1. Clasificación química del agua

El diagrama de barras muestra que el tipo de agua Bicarbonatada es el más frecuente en el inventario,

seguido por los tipos Clorurada y Sulfatada. El gráfico de torta complementa esta información al mostrar que los tres tipos principales concentran más del 80 % de los registros. Esta distribución es consistente con la geología del país: la mayor parte del territorio colombiano está cubierto por rocas sedimentarias carbonatadas que producen aguas bicarbonatadas, mientras que los sectores de actividad volcánica activa generan aguas sulfatadas y cloruradas.

7.7.2. Olor del agua





El diagrama de barras de olor revela que la mayoría de los manantiales registra olor ausente o leve, mientras que una fracción importante presenta olor a H_2S (sulfuro de hidrógeno). El gráfico de barras apilado proporcional, que compara CLASIFICACION_LIMPIA con OLOR_LIMPIO, muestra que los manantiales de tipo Sulfatada concentran la mayor proporción de olor a H_2S . Este resultado es geolquímicamente coherente: el agua sulfatada proviene de ambientes con oxidación de sulfuros metálicos, proceso que libera H_2S como subproducto. Se utilizó `position = 'fill'` en lugar de `position = 'dodge'` porque las frecuencias de cada tipo de agua son muy distintas; con barras simples, los tipos poco frecuentes serían invisibles y la comparación de proporciones resultaría engañosa.


7.7.3. Distribución temporal



El diagrama de barras por año muestra que las mediciones no están distribuidas uniformemente en el tiempo. Algunos años concentran una cantidad desproporcionada de registros, lo que indica que el dataset es el resultado de campañas de muestreo puntuales y no de un monitoreo continuo. Este sesgo temporal debe tenerse en cuenta al interpretar los resultados: el inventario no necesariamente refleja el estado actual de los manantiales, sino el de los períodos en que se realizaron las mediciones.

8. Figuras del análisis exploratorio

8.1. Variables numéricas









8.2 Variables categóricas



**Distribución porcentual
del olor del agua**



Proporción de tipos de agua



9. Conclusiones

El análisis exploratorio del inventario gequímico de manantiales y fumarolas colombianos permitió caracterizar el estado fisicoquímico de 320 puntos de afloramiento de agua subterránea a lo largo del territorio nacional, evidenciando patrones consistentes con la geología volcánica y tectónica del país.

En cuanto a las variables numéricas, se encontró que la mayoría de los manantiales presentan aguas ligeramente ácidas, con una mediana de pH de 6.51, valor más representativo que la media (6.33) debido a la presencia de registros con pH cercano a cero que sesgan la distribución hacia la izquierda (asimetría = -1.66). La temperatura mediana de 39°C confirma que el dataset está dominado por aguas termales, consistente con la actividad geotérmica del país. Variables como la conductividad eléctrica y el sodio presentaron las distribuciones más asimétricas del análisis (asimetría de 13.19 y 5.29 respectivamente), con valores extremos que distorsionan completamente la media clásica; en estos casos, la mediana y la MEDA resultaron ser los únicos estimadores confiables de tendencia central y dispersión.

Respecto a las variables categóricas, el agua de tipo Bicarbonatada representa el 46.6 % del total de registros, lo que refleja la predominancia de rocas sedimentarias carbonatadas en el subsuelo colombiano. El 69.8 % de los manantiales no presenta olor detectable, mientras que los manantiales de tipo Sulfatada concentran la mayor proporción de olor a H_2S , confirmando su asociación con ambientes de oxidación de sulfuros de origen volcánico.

El gráfico de dispersión entre temperatura y pH reveló una tendencia negativa: los manantiales más calientes tienden a ser más ácidos, lo que es coherente con el aporte de gases ácidos (CO_2 , H_2S) provenientes de fluidos magmáticos profundos. La correlación positiva entre sodio y conductividad confirmó que el sodio es el principal ion responsable de la mineralización eléctrica del agua en estos sistemas.

Finalmente, el análisis de datos crudos evidenció la necesidad de una etapa de limpieza rigurosa: se identificaron valores de pH iguales a 0.0, temperaturas de 0°C y concentraciones negativas de algunos iones, todos ellos errores de registro que deberán ser tratados antes de cualquier modelo predictivo. Este trabajo sienta las bases para una etapa posterior de imputación, normalización y modelado que permita estimar el comportamiento de los manantiales en ho-

rizontes de 5 a 10 años, contribuyendo a la gestión sostenible de los recursos hídricos y geotérmicos de Colombia.

10. Referencias

Referencias

- [1] Portal de datos abiertos Servicio geológico colombiano Vol. 374 (2003) p. 201-205.